深度全身控制：学习操作与运动的统一策略

Zipeng Fu[*]、***Xuxin Cheng***[*]、***Deepak Pathak***，卡内基梅隆大学

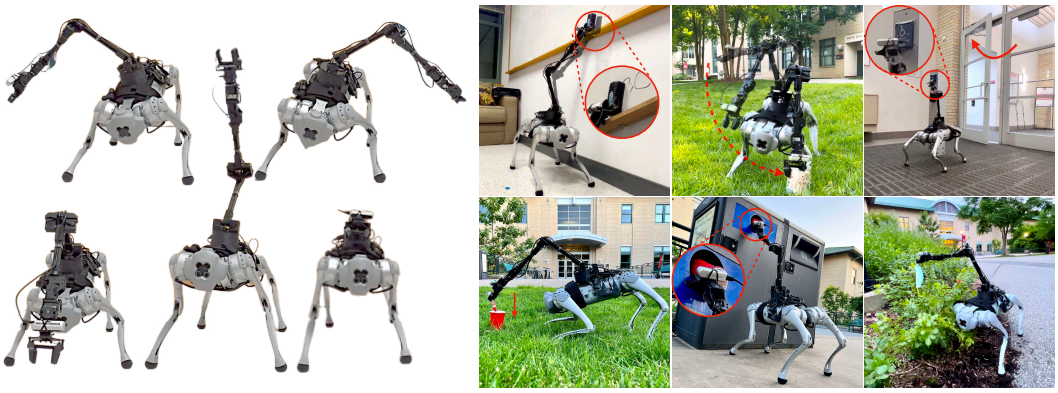


图1：我们提出了一种全身控制框架，用于控制装有机械臂的腿式机器人。左半部分展示了全身控制如何通过腿部弯曲和伸展来获得更大的工作空间。右半部分展示了不同的真实世界任务，包括擦拭白板、拿起杯子、按下开门按钮、放置物品、将杯子扔进垃圾桶，以及在杂乱环境中拾取物体。视频请见项目网站。

摘要：附加机械臂能显著提升腿式机器人在多种移动操作任务中的适用性，而这些任务是轮式或履带式机器人无法完成的。此类腿式操作机器人的标准模块化控制流程是将控制器解耦为操作控制和运动控制。然而，这种方法是低效的：它需要大量的工程工作来支持机械臂与腿部之间的协调，且误差会在模块间传播，产生不连续、不自然的动作。此外，鉴于已有证据表明肢体之间存在强烈的运动协同作用，这种解耦在生物学上也不合理。在这项工作中，我们提出使用强化学习为腿式操作机器人学习一个用于全身控制的统一策略。我们提出正则化在线自适应，以弥合高自由度控制中的仿真到现实差距；并提出优势混合，利用动作空间中的因果依赖性来克服全身系统训练过程中的局部最优问题。我们还展示了一种低成本腿式操作机器人的简单设计，并发现我们的统一策略能够在多种任务场景下表现出动态、敏捷的行为。视频位于 https://maniploco.github.io

关键词：移动操作、全身控制、足式运动

1 引言

腿式运动在过去十年中表现出了令人瞩目的性能，能够在具有挑战性的室内外地形上实现移动，而这些地形是轮式或履带式同类机器人无法到达的。然而，纯腿式机器人所能完成的任务有很大局限，因为即便是最基本的日常任务，除视觉检查外，也需要某种形式的操作能力。这引起了人们对构建腿臂机器人（即同时具备腿和臂的机器人）的广泛兴趣，并推动了相关进展；这些进展主要

[*]同等贡献；ZF 现任职于斯坦福大学。

第 6 届机器人学习会议（CoRL 2022），新西兰奥克兰。

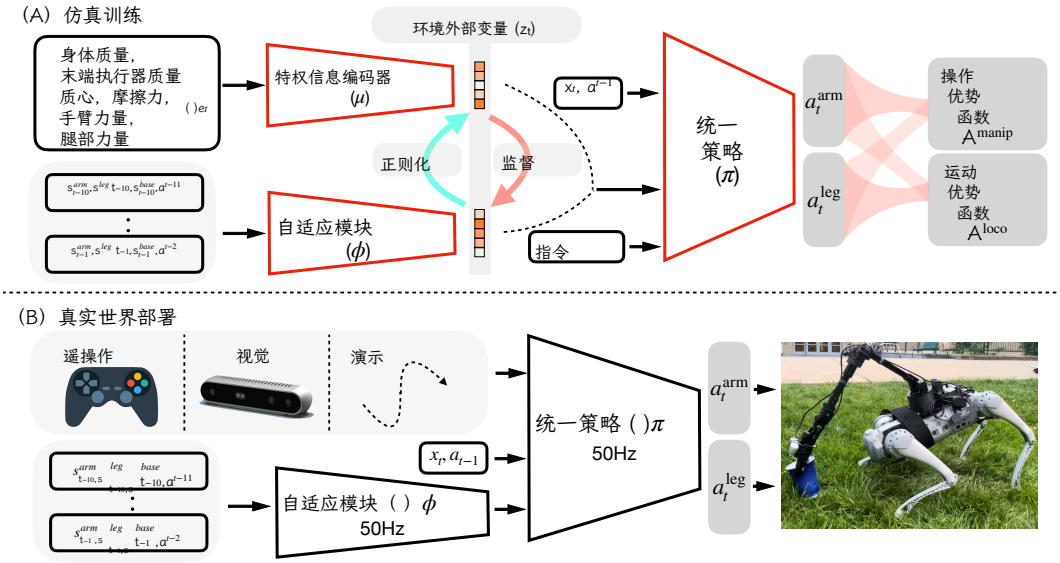


图 2：全身控制框架。训练时，统一策略以环境外部信息为条件进行学习。部署时，直接复用自适应模块，无需任何真机微调。可通过多种模式对机器人下达指令，包括遥操作、视觉和示范回放。

是迄今通过动力学物理建模 [1, 2, 3, 4, 5, 6]实现的。然而，为带机械臂的腿式机器人建模是一个动态、高自由度且非光滑的控制问题，需要设计者具备深厚的领域专业知识并投入大量的工程精力。控制框架往往是模块化的，对不同控制空间分别处理运动学约束 [7], ，因此仅限于在受限环境中运行，泛化能力有限。基于学习的方法，如强化学习（RL），可以降低工程负担，同时有助于提升模型在多样化场景中的泛化能力。

然而，近期针对腿式移动操作机器人 [8] 的基于学习方法，也沿袭了其基于模型的对应方法 [9, 10]，通过半耦合的模块化模型来控制腿部与手臂。这种方法是低效的，原因包括多个实际方面：手臂与腿部缺乏协调、模块间误差传播，以及动作缓慢、不平滑且不自然。此外，它远未达到人类的全身运动控制水平；研究表明，人类四肢之间存在极强的协调性。事实上，手和腿的控制紧密相连，从而形成低维协同，正如俄罗斯生理学家尼古拉·伯恩斯坦 [11, 12, 13]在70多年前一系列开创性著述中所概述的那样。最简单的例子或许是，人在站立时很难让一只手臂和同侧的腿做出不同的动作。全身控制不仅应允许协调，还应扩展各个单独部件的能力。例如，我们的机器人会随着手臂的运动弯曲或伸展腿部，以扩大末端执行器的可达范围，如图1所示。

与腿部运动不同，将标准的 sim2real 强化学习扩展到全身控制并非易事，原因在于以下几个挑战：(a) 高自由度控制：图 3 所示的机器人共有 19 个自由度。这一问题在腿部机械臂中更为严重，因为控制是动态、连续且高频率的，即使在几秒钟的轨迹内也会导致搜索空间呈指数级扩大。(b) 目标冲突与局部最优：考虑当手臂向右倾斜时，机器人需要改变行走步态以平衡重量。这会抑制运动能力，并使训练容易只学好一种模式（操作或运动）。(c) 依赖关系：考虑从地面抓取物体时，手臂的末端执行器需要通过弯曲腿部来获得躯干支撑。这意味着在腿部能够适应之前，操作任务的绝对性能是受限的。

在这项工作中，我们提出了一套面向定制化、低成本且完全无缆束缚的腿臂机器人的硬件配置，以及一种学习统一策略的方法，该策略用于同时控制并协调腿部与机械臂，并兼容如图1所示的多种操作模式。我们使用统一策略进行全身控制，即同时控制四足腿部关节与机械臂，使机械臂末端执行器到达期望位姿，并指令四足机器人移动

	指令跟随 ($r_{\text{following}}$)	能量 (r_{energy})	存活 (r_{alive})
r^{manip}	$0.5 \cdot e^{-\|[p,o]-[p^{\text{cmd}},o^{\text{cmd}}]\|_1}$	$-0.004 \cdot \sum_{j\in\text{手臂关节}} \|\tau_j \dot{q}_j\|$	0
r^{loco}	$-0.5 \cdot \|v_x - v_x^{\text{cmd}}\| + 0.15 \cdot e^{-\|\omega_{\text{yaw}}-\omega^{\text{cmd}}{}_{\text{偏航}}\|}$	$-0.00005 \cdot \sum_{i\in\text{腿部关节}} \|\tau_i \dot{q}_i\|^2$	$0.2 + 0.5 \cdot v_x^{\text{cmd}}$

表 1：操作奖励和运动奖励均采用如下形式： $r_{\text{following}} + r_{\text{energy}} + r_{\text{alive}}$，该奖励鼓励指令跟踪，同时惩罚正向机械能消耗，以实现平滑运动 [17]。记机身前向线速度为 v_x，机身偏航角速度为 ω_{yaw}，扭矩为 τ，关节角速度为 $\dot{q}$。

以期望速度。该方法的关键洞察在于，我们可以利用动作空间中与操作和运动相关的因果结构来稳定并加速学习，并且对域适应加入正则化能够弥合具有完整状态信息的仿真环境与仅具有部分观测的真实世界之间的差距。

我们在所提出的带机械臂足式机器人上进行了评估。尽管该领域取得了巨大进展，但至今仍没有一种便于学术实验室使用的带机械臂足式机器人。最广为人知的机器人是波士顿动力的 SpotArm [14],，但该机器人自带预先设计好的控制器，无法更改。另一个例子是 ANYmal 机器人，其定制机械臂 [8] 来自 ANYBotics。值得注意的是，这两套硬件配置都非常昂贵（超过 10 万美元）。我们实现了一种简单的低成本设计方案：在低成本的足式 Go1 机器人 [15] 顶部加装一个低成本机械臂（硬件成本 6000 美元）。我们的带机械臂足式机器人只需适中的机载算力就能完全不受线缆束缚地运行。我们展示了学习得到的全身控制器在遥操作、视觉引导控制以及开环控制模式中的有效性，覆盖拾取物体、扔垃圾、按压墙上按钮等任务。我们的机器人展现出动态且敏捷的腿臂协调动作，详见 https://maniploco.github.io 上的视频。

2 方法：协调操作与移动的统一策略

我们将统一策略 π 构建为一个神经网络，其输入为当前基座状态 $s_t^{\text{base}} \in \mathbb{R}^5$ （横滚角、俯仰角和基座角速度）、手臂状态 $s_t^{\text{arm}} \in \mathbb{R}^{12}$ （每个手臂关节的位置和速度）、腿部状态 $s_t^{\text{leg}} \in \mathbb{R}^{28}$ （每个腿部关节的位置和速度，以及足底接触指示）、上一动作 $a_{t-1} \in \mathbb{R}^{18}$、末端执行器的位置和姿态指令 $[p^{\text{cmd}}, o^{\text{cmd}}] \in \mathbb{SE}$ (3)、基座速度指令 $[v_x^{\text{cmd}}, \omega_{\text{yaw}}^{\text{cmd}}]$，以及环境外部参数 $z_t \in \mathbb{R}^{20}$ （详见第 2.2 节）。该策略输出目标手臂关节位置 $a_t^{\text{arm}} \in \mathbb{R}^6$ 和目标腿部关节位置 $a_t^{\text{leg}} \in \mathbb{R}^{12}$，随后通过 PD 控制器将其转换为力矩。我们对腿部和手臂均采用关节空间位置控制。与手臂的操作空间控制相比，关节空间控制可以学习避免自碰撞，并缩小 Sim-to-Real 差距；这也被证实在涉及多个机器人部件的其他设置（如双臂操作 [16]）中是有用的。

我们使用 RL 通过最大化折扣期望回报 $\mathbb{E}_\pi \left[\sum_{t=0}^{T-1} \gamma^t r_t\right]$ 来训练策略 π ，其中 r_t 是时间步 t 处的奖励， γ 是折扣因子， T 是最大回合长度。奖励 r 是操作奖励 r^{manip} 与移动奖励 r^{loco} 的总和，如表 1 所示。注意，我们对每个腿部关节使用能耗的平方，以同时鼓励所有腿部关节的平均能耗更低、方差也更低。我们遵循鼓励最小化来自 [17]的能量消耗的简单奖励设计。

命令变量	训练范围	测试范围
v_x^{cmd}	[0, 0.9]	[0.8, 1.0]
$\omega_{yaw}^{\text{cmd}}$	[-1,0, 1.0]	[-1, -.7]& [.7, 1]
l	[0.2, 0.7]	[0.6, 0.8]
p	$[-2\pi/5, 2\pi/5]$	$[-2\pi/5, 2\pi/5]$
y	$[-3\pi/5, 3\pi/5]$	$[-3\pi/5, 3\pi/5]$
T_{traj}	[1, 3]	[0.5, 1]

表 2：命令变量均匀采样的范围

我们将末端执行器位置命令 p^{cmd} 参数化为球坐标 (l, p, y)，其中 l 为球的半径， p 、 y 分别为俯仰角和偏航角。球坐标系的原点设在机械臂基座处，但不受躯干高度、横滚角和俯仰角的影响（详见补充材料）。我们设置末端执行器位姿命令 p^{cmd} ，方法是在当前末端执行器位置 p 与随机采样得到的末端执行器位置之间进行插值。

环境参数	训练范围	测试范围
基础额外负载	[-0.5, 3.0]	[5.0, 6.0]
末端执行器负载	[0, 0.1]	[0.2, 0.3]
基座质心	[-0.15, 0.15]	[0.20, 0.20]
手臂电机强度	[0.7, 1.3]	[0.6, 1.4]
腿部电机强度	[0.9, 1.1]	[0.7, 1.3]
摩擦系数	[0.25, 1.75]	[0.05, 2.5]

表 3：环境参数均匀采样的范围

每 T_{traj} 秒p^{end}：

$$p_t^{\text{cmd}} = \frac{t}{T_{\text{traj}}} p + \left(1 - \frac{t}{T_{\text{traj}}}\right) p^{\text{end}},\ t \in [0, T_{\text{traj}}].$$

如果任意 p_t^{cmd}导致自碰撞或与地面碰撞，则p^{end} 会被重新采样。 o^{cmd} 从 $\mathbb{SO}(3)$空间中均匀采样。表2列出了所有命令变量的采样范围。

2.1 用于策略学习的优势混合

为高自由度机器人训练鲁棒策略是困难的。在操作与运动学习文献中，研究者们采用课程学习来简化学习过程，即逐步提高任务难度，使策略能够先学会解决简单任务，然后再应对困难任务 [18, 19, 20]。然而，这些工作大多需要对多种课程参数进行大量手动调整，并精心设计自动课程机制。

我们并没有在学习和环境设置中引入大量课程，而是只依赖一个仅有一个参数的课程来加快策略学习。既然知道操作任务大多与手臂动作相关，而运动任务在很大程度上依赖于腿部动作，我们就可以在策略优化中通过混合操作与运动的优势函数来形式化这一归纳偏置，以加速策略学习。形式上，对于一个具有对角高斯噪声的策略以及一个采样得到的转移批次 D，关于策略参数 θ_π 的训练目标是

$$J(\theta_\pi) = \frac{1}{|\mathcal{D}|} \sum_{(s_t, a_t) \in \mathcal{D}} \log \pi(a_t^{\text{arm}} \mid s_t) \left(A^{\text{manip}} + \beta A^{\text{loco}}\right) + \log \pi(a_t^{\text{leg}} \mid s_t) \left(\beta A^{\text{manip}} + A^{\text{loco}}\right)$$

β 是课程参数，随时间步 T_{mix} 从 0 线性增加到 1：$\beta = \min(t/T_{\text{mix}}, 1)$。 A^{manip} 和 A^{loco} 分别是基于 r^{manip} 和 r^{loco} 的优势函数。直观上，优势混合通过先将操作回报中的差异归因于手臂动作、将移动回报中的差异归因于腿部动作，再逐步退火加权优势总和来降低信用分配的复杂度，从而鼓励学习分别有助于移动与操作的手臂动作和腿部动作。我们通过 PPO [21] 优化这一强化学习目标。

2.2 面向仿真到现实迁移的正则化在线自适应

许多关于仿真到现实迁移的先前工作采用两阶段教师-学生方案：首先利用仅在仿真中可用的特权信息，通过强化学习训练教师网络；然后学生网络使用本体观测历史在显式动作空间或潜在空间中模仿教师策略 [22, 23, 24, 25]。由于教师网络可获得的完整状态与学生网络本体传感器的部分可观测性之间存在信息差距，教师网络可能提供学生网络无法预测的监督，从而导致可实现性差距。这一问题在具身智能体社区中也已被指出 [26]。此外，第二阶段只能在第一阶段收敛后才能开始，这给训练和部署都带来了额外负担。

为了解决可实现性差距并消除两阶段流程，我们提出了正则化在线自适应（如图2所示）。具体来说，编码器 μ 以特权信息 e 作为输入，预测环境外部潜在变量 z^μ，以帮助统一策略在不同环境中调整其行为。自适应模块 ϕ 仅基于机器人机载传感器的近期观测历史来估计环境外部潜在变量 z^ϕ。我们通过强化学习将 μ 与统一策略 π 进行端到端联合训练，并对 z^μ 进行正则化，以避免其与自适应模块估计的 z^ϕ 产生较大偏差。自适应模块 ϕ 通过在线模仿 z^μ 进行训练。我们将整个学习流程的损失函数定义为关于策略参数 θ_π、特权信息编码器参数 θ_μ和自适应模块参数 θ_ϕ 的函数：

$$L(\theta_\pi, \theta_\mu, \theta_\phi) = -J(\theta_\pi, \theta_\mu) + \lambda ||z^\mu - \text{sg}[z^\phi]||_2 + ||\text{sg}[z^\mu] - z^\phi||_2 \ ,$$

其中 $J(\theta_\pi, \theta_\mu)$ 是第 2.1 节讨论的 RL 目标，$\text{sg}[\cdot]$ 是停止梯度算子，λ 是作为正则化强度的拉格朗日乘子。该损失函数可以通过对偶梯度下降最小化：$\theta_\pi, \theta_\mu \leftarrow \arg\min_{\theta_\pi, \theta_\mu} \mathbb{E}_{(s,a) \sim \pi(\ldots, z^\mu)}[L]$,

	存活 ↑	基座加速度 ↓	速度误差 ↓	末端执行器误差 ↓	总能量 ↓
统一（本文方法）	**97.1** $\pm$ 0.61	**1.00** $\pm$ 0.03	**0.31** $\pm$ 0.03	**0.63** $\pm$ 0.02	50 $\pm$ 0.90
分离	92.0 $\pm$ 0.90	1.40 $\pm$ 0.04	0.43 $\pm$ 0.07	0.92 $\pm$ 0.10	51 $\pm$ 0.30
不协调	94.9 $\pm$ 0.61	1.03 $\pm$ 0.01	0.33 $\pm$ 0.01	0.73 $\pm$ 0.02	**50** $\pm$ 0.28

Tabl表4：统一策略与腿臂分离策略以及一种不协调策略的比较。 e
统一策略在相同能耗下达到最佳性能。测试范围见表2。

$\theta_\phi \leftarrow \arg\min_{\theta_\phi} \mathbb{E}_{(s,a)\sim\pi(\ldots,z^\phi)}[L]$，以及 $\lambda \leftarrow \lambda + \alpha \frac{\partial L}{\partial \lambda}$，步长为 α。已知该优化过程在温和条件下会收敛 [27, 28]。实践中，我们以固定的梯度步数交替优化统一策略 π 与编码器 μ，以及自适应模块 ϕ。λ 按固定线性方案从0增加到1。注意，RMA [22] 是正则化在线自适应的一种特例，其中拉格朗日乘子 λ 被设为恒为零，自适应模块 ϕ 仅在策略 π 与编码器 μ收敛后才开始训练。

部署：在部署过程中，统一策略与自适应模块在机载端联合执行。为了指定指令，我们开发了三种接口：通过操纵杆进行远程操作、通过RGB跟踪进行闭环控制，以及对人类示范进行开环重放。详见第3.3节。

3 实验结果

3.1 机器人系统搭建

机器人平台由一台 Unitree Go1 四足机器人 [15]（具有 12 个可驱动自由度）和一台 6 自由度 Interbotix WidowX 250s 机械臂 [29]（带有平行夹爪）组成。我们将机械臂安装在四足机器人顶部。RealSense D435 提供 RGB 视觉信息，并安装在 WidowX 夹爪附近。Go1 和 WidowX 的电力均由 Go1 的机载电池提供。神经网络推理同样在 Go1 的机载平台上完成。我们的机器人系统仅使用机载计算和机载电源，因此完全不受线缆束缚。

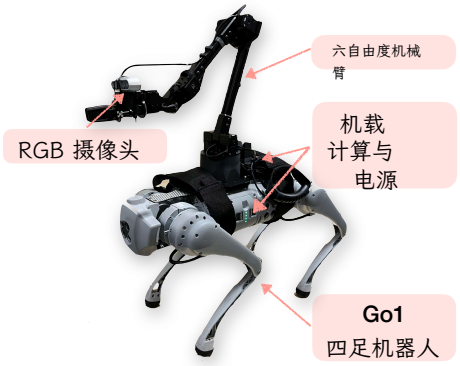


图3：机器人系统搭建

3.2 仿真实验

我们的仿真实验旨在回答以下问题：

- 统一策略是否优于分别控制机械臂和腿部的独立策略？如果是，其优势体现在哪些方面？
- 优势混合如何帮助学习统一策略？
- 与其他Sim2Real方法相比，正则化的在线自适应性能如何？

基线与评估指标：我们将我们的方法与以下基线方法进行比较：

1. 腿部与机械臂的独立策略：一个策略基于四足机器人观测控制腿部，另一个策略基于机械臂观测控制机械臂。2. 不协调策略：与统一策略相同，观察基座、腿部和机械臂的聚合状态，但仅使用 r^{manip} 训练机械臂动作，仅使用 r^{loco} 训练腿部动作。3. 快速运动自适应（RMA）[22]：两阶段的教师-学生基线方法。4. 专家策略：使用特权信息编码器 z^μ的统一策略。5. 域随机化：不使用环境外部因素 z训练的统一策略。

我们报告以下指标：（1）存活率，（2）基座加速度：基座的角加速度，（3）速度误差：基座速度指令与实际基座速度之间的L1误差，（4）末端执行器（EE）误差：末端执行器（EE）指令与实际EE之间的L1误差

	机械臂工作空间（m^3）↑	在↑扰动下的存活
统一（我们的）	**0.82** $\pm$ 0.02	**0.87** $\pm$ 0.04
分离	0.58 $\pm$ 0.10	0.64 $\pm$ 0.06
不协调	0.65 $\pm$ 0.02	0.77 $\pm$ 0.06

表5：在统一策略中，腿部有助于扩大手臂的工作空间，而手臂则帮助四足机器人保持稳定。

姿态，（5）总能量：腿部与手臂消耗的总能量。所有指标均按回合长度归一化。所有实验均在3个随机初始化的网络上进行测试，每个网络运行1000个回合。仿真和训练详情见补充材料。

	可实现性差距 $\|z^{\mu} - z^{\phi}\|_2$ ↓	存活率 ↑	基座加速度 ↓	速度误差 ↓	末端执行器误差 ↓	总能量↓
域随机化	-	95.8 ± 0.2	$\mathbf{0.44} \pm 0.00$	0.46 ± 0.00	0.40 ± 0.00	$\mathbf{21.9} \pm 0.53$
RMA [22]	0.31 ± 0.01	95.2 ± 0.2	0.54 ± 0.02	0.44 ± 0.00	0.26 ± 0.04	27.3 ± 0.95
正则化在线自适应（本文方法）	$\mathbf{2e\text{-}4} \pm 0.00$	$\mathbf{97.4} \pm 0.1$	0.51 ± 0.02	$\mathbf{0.39} \pm 0.01$	$\mathbf{0.21} \pm 0.00$	25.9 ± 0.56
带正则化的专家	-	97.8 ± 0.2	0.52 ± 0.02	0.40 ± 0.01	0.21 ± 0.00	25.8 ± 0.49
不带正则化的专家	-	98.3 ± 0.2	0.51 ± 0.02	0.39 ± 0.00	0.21 ± 0.00	25.6 ± 0.30

表6：正则化在线自适应（Regularized Online Adaptation）优于其他基线，其模仿误差最小，这使其能达到与使用特权信息预测环境外部因素的专家策略相同的性能。使用正则化项 $\|z^{\mu} - \text{sg}[z^{\phi}]\|_2$ 训练的专家策略与不使用正则化训练的专家策略相比，性能退化可忽略不计。测试范围见表3。域随机化（Domain Randomization）在大多数情况下仅学会站立，因此其总能量和基座加速度会平凡地降到较低水平。

统一策略相较于基线的改进：在表4中，我们的统一策略优于分离且不协调的策略，因为手臂和腿部动作均使用操作与运动的奖励总和进行训练，并接收来自手臂、腿部以及四足机器人基座的观测；而基线方法难以维持较小的基座加速度，导致在指令速度跟踪和末端执行器位姿跟踪方面产生较大误差。

统一策略增强全身协调性：表5显示，我们的统一策略促进了全身协调，表现为：(1) 腿部动作会通过针对较低末端执行器指令进行弯曲、针对较高末端执行器指令站高，来帮助手臂实现更大的工作空间；(2) 手臂会帮助机器人在较大扰动（基座初速度1.0 m/s）下保持平衡，从而使统一策略具有更高的存活率。我们通过计算1000个采样末端执行器位姿的凸包体积，再减去包围四足机器人的立方体体积，来估计手臂的工作空间。

优势混合有助于统一策略的学习：不使用优势混合时，统一策略在信用分配上存在困难，导致策略先学习末端执行器指令跟踪，却忽略了运动任务。如图4所示，优势混合帮助策略先专注于每个任务，然后再将它们合并，这引入了一种类似课程学习的机制，从而加速训练。详见补充材料。

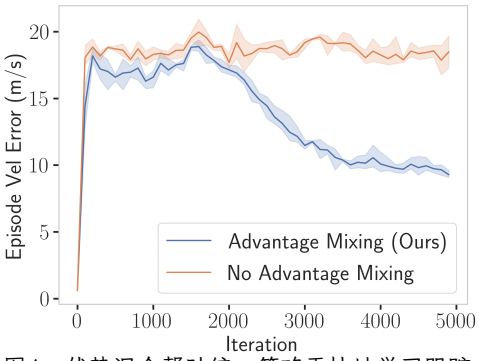


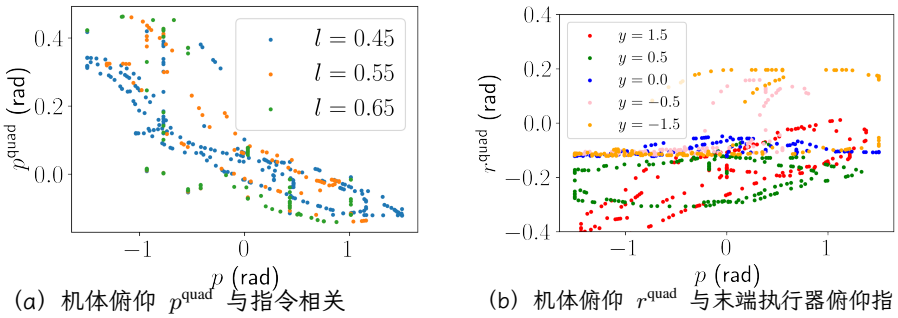
图4：优势混合帮助统一策略更快地学习跟踪速度指令，优于不进行混合的情况（各回合的聚合速度误差急剧下降）。

正则化在线自适应的鲁棒OOD性能：我们在表3中所示的具有分布外（OOD）环境参数的环境中进行测试，发现我们的正则化在线自适应比RMA和域随机化（DR）更鲁棒。在RMA中，自适应模块估计出的环境外参并不保证能够模仿专家所学习到的外参。借助正则化在线自适应，专家在自适应模块的正则化下学习预测环境外参，因此模仿误差很小，EE误差降低了20%。表6显示，为专家添加正则化对性能的负面影响可忽略不计；同时，由于潜在模仿误差更小，相比RMA，每项指标都得到了改善。需要注意的是，在困难环境下DR只是原地站立，因此其机体加速度和总能量更好。

3.3 真实世界实验

我们使用Go1内置的MPC控制器和用于WidowX操作空间控制的IK求解器作为真实世界中的基线，我们称之为MPC+IK。更多细节见补充材料。

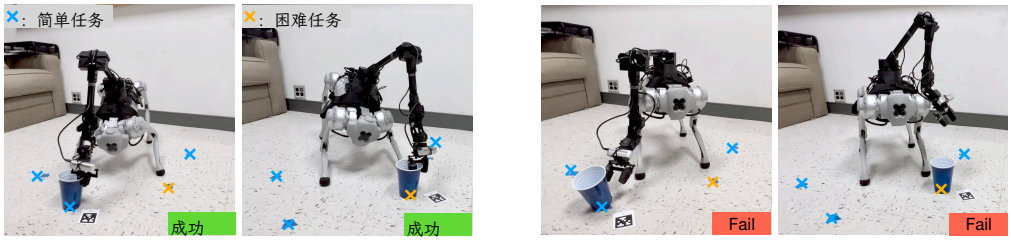
遥操作：我们通过参数化 $p_{t+1}^{\text{cmd}} = p_t^{\text{cmd}} + \Delta p$ 来指定末端执行器（EE）位置指令 p_t^{cmd}，其中 $\Delta p = (\Delta l, \Delta p, \Delta y)$ 由两个操纵杆指定。有操作员在回路中时，我们可以命令末端执行器到达训练分布以内或以外的点。在图5中，我们分析了真实世界环境中的全身控制，结果显示四足机器人的机体旋转 $(r^{\text{quad}}, p^{\text{quad}}, y^{\text{quad}})$ 与末端执行器位置指令 p_t^{cmd} 高度相关。这表明我们的统一策略实现了全身协调，腿部关节和机械臂关节共同帮助完成到达动作。



(a) 机体俯仰 p^{quad} 与指令相关末端执行器俯仰 p （不同长度 l）。

(b) 机体俯仰 r^{quad} 与末端执行器俯仰指令 p 在不同偏航 y 下相关。

图 5：真实世界全身控制分析。（a）我们固定末端执行器偏航指令 $y = 0$，改变末端执行器俯仰指令 p 和长度 l。当 p 的幅值较大时，四足机器人会向上或向下俯仰，以帮助机械臂到达目标。随着 l 增大（目标更远），四足机器人会俯仰更多以提供帮助。（b）当末端执行器偏航指令 y 的幅值更接近 1.578（机械臂转向躯干一侧）时，四足机器人会侧倾更多以帮助机械臂。当 $y = 0$ 时，四足机器人会向下俯仰而不是侧倾，以帮助机械臂。



(a) 我们的方法：在简单和困难任务中均能成功并以协调的行为完成这些任务。

(b) MPC+IK：两种场景下均失败。左侧：因漏抓杯子而失败。右侧：因自身碰撞而失败。

图6：视觉引导抓取任务中我们的方法与基线控制器（MPC+IK）的对比。我们在机器人周围采样不同点作为目标抓取位置。简单任务：3个点位于距机器人的正常距离处。困难任务：当点非常靠近前脚且没有全身控制时难以到达。更多困难任务见补充材料。视频见 https://maniploco.github.io

视觉引导跟踪：除了由人类进行摇杆控制外，我们还展示了利用RGB相机视觉反馈完成的成功抓取任务。我们在机械臂夹爪附近安装了一个Realsense D435i相机，并使用AprilTag [30] 来获取夹爪与被抓取物体之间的相对位置。AprilTag是一种在机器人研究中常用的视觉基准系统，通过简单的二维黑白方块来编码位姿信息。我们首先获取AprilTag在相机坐标系 $p^{\text{tag}} = [x^{\text{tag}}, y^{\text{tag}}, z^{\text{tag}}]^T$ 中的平移量。

	成功 Rate ↑	TTC ↓	IK 失败 Rate ↓	自身碰撞 Rate ↓
简单任务（在 3 个点上测试）				
Ours	**0.8**	**5s**	-	**0**
MPC+IK	0.3	17s	0.4	0.3
困难任务（在 5 个点上测试）				
Ours	**0.8**	**5.6s**	-	**0**
MPC+IK	0.1	22.0s	0.2	0.5

表7：我们的方法与 MPC+IK 在拾取任务上的比较。p^{end} 是从地面上的点中采样的目标位置。TTC 是平均完成时间。每个任务的性能是对10次真实世界试验取平均值。

然后，我们设计并使用一个简单而有效的位置反馈控制器来设置当前末端执行器（EE）的位置指令 $p_t^{\text{cmd}} = K^T p^{\text{tag}}$，其中 $K = [-1.5, -1.5, 0.1]^T$ 是位置控制的增益向量。在图6和表7中，我们比较了我们的方法与基线（MPC+IK）在若干抓取任务中的表现，测量了每种设置下的成功率、平均完成时间（TTC）、IK失败率和自碰撞率。我们在执行前将机器人初始化为相同的默认配置。

成功与失败模式分析：我们的方法在简单任务上大多数时候都能成功，且在困难任务上没有明显的性能下降。我们方法的失败尝试很大程度上是由于实际杯子位置与AprilTag位置之间的不匹配造成的，可以通过使用两个AprilTags并对其位姿取平均来缓解（详见补充材料）。由于视觉估计不是本工作的重点，我们推断我们的方法在拾取任务上比MPC+IK具有更高的精度和效率。MPC+IK在一些简单任务上能够成功，但因IK奇异点或自碰撞而失败。在困难任务中，主要失败原因是自碰撞，因为杯子太靠近

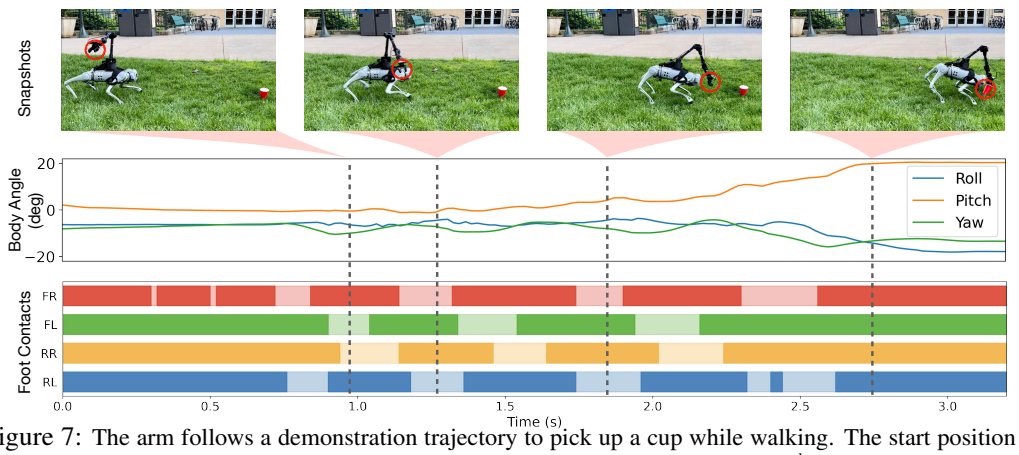


Figure 7: The arm follows a demonstration trajectory to pick up a cup while walking. The start position is $p = (0.5, -0.5, -1.2)$, at the right upper side of the robot and the end position is $p^{\text{end}} = (0.55, -0.9, 0.4)$, on the left lower front side close to the ground. $T_{\text{traj}} = 2.5s$. The robot initially stands on the ground and then is commanded by a constant forward velocity $v_x^{\text{cmd}} = 0.35$. Meanwhile the EE position command changes. When EE position command is high, the quadruped starts to walk without significant tilting behavior with a natural walking gait. As the EE position command moves below the torso, the quadruped starts to pitch downwards, roll to the left and yaw slightly to the right to help the arm reach the goal.

body. Notice that the TTC of MPC+IK is also longer than our method because solving online IK and operational space control more computationally demanding than joint position control (ours).

Open-loop Control from Demonstration: In this part, we analyze how agile walking is coupled with dynamic arm movement. The robot is given a pre-defined end-effector trajectory to follow in an open-loop manner while being commanded to walk at the same time. Results in Figure 7 show **agility** and **dynamic coordination** of our legged manipulator on uneven grass terrain powered by our whole-body control method.

4 Related Work

Legged Locomotion Traditional model-based control methods for legged robots have shown success but often require controllers to be meticulously designed and many manual tunings [1, 2, 3, 4, 5, 31, 32, 33, 34, 35, 36, 6, 37]. The extra weight and movement of a robot arm on top of the legged robot will make such design process more challenging. Recent advances in reinforcement learning enable legged robots to traverse challenging terrains and adapt to changing dynamics [38, 24, 22, 39, 40, 41, 42, 43, 44, 45, 46, 47, 17, 48, 49, 50]. However these works only focus on the mobility part and few interactions with objects or the environment by manipulation are studied.

Mobile Manipulation Adding mobility to manipulation is studied in [51, 52, 53, 8, 54, 55, 10, 9, 56, 57, 58]. Advances have also been made in the field of biped humanoid [59, 60, 61, 62]. More recently, Ma et al. [8] proposed using an MPC controller to track the desired end-effector position of the arm mounted on a quadruped with a RL policy to maintain balance. However, the controllers for legs (RL) and arm (model-based) are separate modules and no dynamic movements are demonstrated. In [55], language models are used to guide a mobile robot to finish different tasks using the arm. However, the manipulation and mobility are utilized in a decoupled step-by-step manner.

5 Discussion and Limitations

We proposed a hardware setup as well as an algorithm to learn whole-body control of a legged robot with robotic arm. Our policy shows coordination between legs and arm while being able to control them in a dynamic manner. Although we have shown preliminary results on object interaction (e.g. picking, pressing, erasing), incorporating general-purpose object interaction (e.g. occlusion and soft object) into the our unified policy is a challenging open research direction. There are several ways in which the current methodology could be extended, such as, learning vision-based policies from the egocentric camera mounted on torso [63] and on the arm, climbing on the obstacle using front legs to pick something up on the table where the arm alone cannot reach, and etc. We believe this paper provides a first step towards several of such future directions.

Acknowledgments

We would like to thank Chris Atkeson for high-quality feedback, and Kenny Shaw, Russell Mendonca, Ellis Brown, Heng Yu, Unitree Robotics (Irving Chen, Yunguo Cui and Walter Wen) and staff at CMU Tech Spark for help in real-world experiments, hardware design and assembly. This work is supported in part by DARPA Machine Common Sense grant and ONR N00014-22-1-2096.

References

[1] H. Miura and I. Shimoyama. Dynamic walk of a biped. *IJRR*, 1984.

[2] M. H. Raibert. Hopping in legged systems—modeling and simulation for the two-dimensional one-legged case. *IEEE Transactions on Systems, Man, and Cybernetics*, 1984.

[3] H. Geyer, A. Seyfarth, and R. Blickhan. Positive force feedback in bouncing gaits? *Proceedings of the Royal Society of London. Series B: Biological Sciences*, 2003.

[4] K. Yin, K. Loken, and M. Van de Panne. Simbicon: Simple biped locomotion control. *ACM Transactions on Graphics*, 2007.

[5] K. Sreenath, H.-W. Park, I. Poulakakis, and J. W. Grizzle. A compliant hybrid zero dynamics controller for stable, efficient and fast bipedal walking on mabel. *IJRR*, 2011.

[6] M. Hutter, C. Gehring, D. Jud, A. Lauber, C. D. Bellicoso, V. Tsounis, J. Hwangbo, K. Bodie, P. Fankhauser, M. Bloesch, et al. Anymal-a highly mobile and dynamic quadrupedal robot. In *IROS*, 2016.

[7] L. Sentis and O. Khatib. A whole-body control framework for humanoids operating in human environments. In *ICRA*, 2006.

[8] Y. Ma, F. Farshidian, T. Miki, J. Lee, and M. Hutter. Combining learning-based locomotion policy with model-based manipulation for legged mobile manipulators. *RA-L*, 2022.

[9] C. D. Bellicoso, K. Krämer, M. Stäuble, D. Sako, F. Jenelten, M. Bjelonic, and M. Hutter. Alma-articulated locomotion and manipulation for a torque-controllable robot. In *ICRA*, 2019.

[10] S. Zimmermann, R. Poranne, and S. Coros. Go fetch!-dynamic grasps using boston dynamics spot with external robotic arm. In *ICRA*, 2021.

[11] N. Bernstein. The co-ordination and regulation of movements. *The co-ordination and regulation of movements*, 1966.

[12] M. L. Latash. The bliss (not the problem) of motor abundance (not redundancy). *Experimental brain research*, 217(1):1–5, 2012.

[13] M. Bruton and N. O'Dwyer. Synergies in coordination: a comprehensive overview of neural, computational, and behavioral approaches. *Journal of Neurophysiology*, 120(6):2761–2774, 2018.

[14] B. Dynamics. Spot Arm. https://www.bostondynamics.com/.

[15] X. Wang. Unitree go1. https://www.unitree.com/products/go1/.

[16] S. Kataoka, S. K. S. Ghasemipour, D. Freeman, and I. Mordatch. Bi-manual manipulation and attachment via sim-to-real reinforcement learning. *arXiv preprint arXiv:2203.08277*, 2022.

[17] Z. Fu, A. Kumar, J. Malik, and D. Pathak. Minimizing energy consumption leads to the emergence of gaits in legged robots. In *CoRL*, 2021.

[18] G. B. Margolis, G. Yang, K. Paigwar, T. Chen, and P. Agrawal. Rapid locomotion via reinforcement learning. *RSS*, 2022.

[19] N. Rudin, D. Hoeller, P. Reist, and M. Hutter. Learning to walk in minutes using massively parallel deep reinforcement learning. In *CoRL*, 2022.

[20] I. Akkaya, M. Andrychowicz, M. Chociej, M. Litwin, B. McGrew, A. Petron, A. Paino, M. Plappert, G. Powell, R. Ribas, et al. Solving rubik's cube with a robot hand. *arXiv preprint arXiv:1910.07113*, 2019.

[21] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov. Proximal policy optimization algorithms. *arXiv:1707.06347*, 2017.

[22] A. Kumar, Z. Fu, D. Pathak, and J. Malik. RMA: Rapid Motor Adaptation for Legged Robots. In *RSS*, 2021.

[23] G. B. Margolis, T. Chen, K. Paigwar, X. Fu, D. Kim, S. bae Kim, and P. Agrawal. Learning to jump from pixels. In *CoRL*, 2021.

[24] J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun, and M. Hutter. Learning quadrupedal locomotion over challenging terrain. *Science Robotics*, 2020.

[25] T. Miki, J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun, and M. Hutter. Learning robust perceptive locomotion for quadrupedal robots in the wild. *Science Robotics*, Jan. 2022.

[26] L. Weihs, U. Jain, I.-J. Liu, J. Salvador, S. Lazebnik, A. Kembhavi, and A. Schwing. Bridging the imitation gap by adaptive insubordination. *NeurIPS*, 2021.

[27] S. Levine, C. Finn, T. Darrell, and P. Abbeel. End-to-end training of deep visuomotor policies. *JMLR*, 2016.

[28] H. Wang and A. Banerjee. Bregman alternating direction method of multipliers. *NeurIPS*, 2014.

[29] WidowX 250 robot arm 6DOF - X-Series robotic arm. https://www.trossenrobotics.com/widowx-250-robot-arm-6dof.aspx.

[30] E. Olson. AprilTag: A robust and flexible visual fiducial system. In *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, pages 3400–3407. IEEE, May 2011.

[31] A. M. Johnson, T. Libby, E. Chang-Siu, M. Tomizuka, R. J. Full, and D. E. Koditschek. Tail assisted dynamic self righting. In *Adaptive Mobile Robotics*. World Scientific, 2012.

[32] M. Khoramshahi, H. J. Bidgoly, S. Shafiee, A. Asaei, A. J. Ijspeert, and M. N. Ahmadabadi. Piecewise linear spine for speed–energy efficiency trade-off in quadruped robots. *Robotics and Autonomous Systems*, 2013.

[33] A. D. Ames, K. Galloway, K. Sreenath, and J. W. Grizzle. Rapidly exponentially stabilizing control lyapunov functions and hybrid zero dynamics. *IEEE Transactions on Automatic Control*, 2014.

[34] D. J. Hyun, J. Lee, S. Park, and S. Kim. Implementation of trot-to-gallop transition and subsequent gallop on the mit cheetah i. *IJRR*, 2016.

[35] M. Barragan, N. Flowers, and A. M. Johnson. MiniRHex: A small, open-source, fully programmable walking hexapod. In *RSS Workshop*, 2018.

[36] G. Bledt, M. J. Powell, B. Katz, J. Di Carlo, P. M. Wensing, and S. Kim. Mit cheetah 3: Design and control of a robust, dynamic quadruped robot. In *IROS*, 2018.

[37] C. S. Imai, M. Zhang, Y. Zhang, M. Kierebinski, R. Yang, Y. Qin, and X. Wang. Vision-guided quadrupedal locomotion in the wild with multi-modal delay randomization. *arXiv:2109.14549*, 2021.

[38] J. Hwangbo, J. Lee, A. Dosovitskiy, D. Bellicoso, V. Tsounis, V. Koltun, and M. Hutter. Learning agile and dynamic motor skills for legged robots. *Science Robotics*, 2019.

[39] Z. Li, X. Cheng, X. B. Peng, P. Abbeel, S. Levine, G. Berseth, and K. Sreenath. Reinforcement learning for robust parameterized locomotion control of bipedal robots. In *ICRA*, 2021.

[40] X. B. Peng, E. Coumans, T. Zhang, T.-W. E. Lee, J. Tan, and S. Levine. Learning agile robotic locomotion skills by imitating animals. In *RSS*, 2020.

[41] W. Yu, J. Tan, C. K. Liu, and G. Turk. Preparing for the unknown: Learning a universal policy with online system identification. In *RSS*, 2017.

[42] W. Yu, C. K. Liu, and G. Turk. Policy transfer with strategy optimization. In *ICLR*, 2018.

[43] W. Zhou, L. Pinto, and A. Gupta. Environment probing interaction policies. In *ICLR*, 2019.

[44] W. Yu, V. C. V. Kumar, G. Turk, and C. K. Liu. Sim-to-real transfer for biped locomotion. In *IROS*, 2019.

[45] W. Yu, J. Tan, Y. Bai, E. Coumans, and S. Ha. Learning fast adaptation with meta strategy optimization. *RA-L*, 2020.

[46] X. Song, Y. Yang, K. Choromanski, K. Caluwaerts, W. Gao, C. Finn, and J. Tan. Rapidly adaptable legged robots via evolutionary meta-learning. In *IROS*, 2020.

[47] I. Clavera, A. Nagabandi, S. Liu, R. S. Fearing, P. Abbeel, S. Levine, and C. Finn. Learning to adapt in dynamic, real-world environments through meta-reinforcement learning. In *ICLR*, 2019.

[48] L. Smith, J. C. Kew, X. B. Peng, S. Ha, J. Tan, and S. Levine. Legged robots that keep on learning: Fine-tuning locomotion policies in the real world. In *ICRA*, 2022.

[49] R. Yang, M. Zhang, N. Hansen, H. Xu, and X. Wang. Learning vision-guided quadrupedal locomotion end-to-end with cross-modal transformers. In *ICLR*, 2022.

[50] Z. Fu, A. Kumar, A. Agarwal, H. Qi, J. Malik, and D. Pathak. Coupling vision and proprioception for navigation of legged robots. In *CVPR*, 2022.

[51] C. Sun, J. Orbik, C. M. Devin, B. H. Yang, A. Gupta, G. Berseth, and S. Levine. Fully autonomous real-world reinforcement learning with applications to mobile manipulation. In *CoRL*, 2022.

[52] J. Wong, A. Tung, A. Kurenkov, A. Mandlekar, L. Fei-Fei, S. Savarese, and R. Martín-Martín. Error-aware imitation learning from teleoperation data for mobile manipulation. In *CoRL*, 2022.

[53] D. Honerkamp, T. Welschehold, and A. Valada. Learning kinematic feasibility for mobile manipulation through deep reinforcement learning. *RA-L*, 2021.

[54] X. Ding and F. Yang. Study on hexapod robot manipulation using legs. *Robotica*, 34(2): 468–481, Feb. 2016.

[55] M. Ahn, A. Brohan, N. Brown, Y. Chebotar, O. Cortes, B. David, C. Finn, K. Gopalakrishnan, K. Hausman, A. Herzog, D. Ho, J. Hsu, J. Ibarz, B. Ichter, A. Irpan, E. Jang, R. J. Ruano, K. Jeffrey, S. Jesmonth, N. J. Joshi, R. Julian, D. Kalashnikov, Y. Kuang, K.-H. Lee, S. Levine, Y. Lu, L. Luu, C. Parada, P. Pastor, J. Quiambao, K. Rao, J. Rettinghouse, D. Reyes, P. Sermanet, N. Sievers, C. Tan, A. Toshev, V. Vanhoucke, F. Xia, T. Xiao, P. Xu, S. Xu, and M. Yan. Do as I can, not as I say: Grounding language in robotic affordances. 2022.

[56] F. Xia, C. Li, R. Martín-Martín, O. Litany, A. Toshev, and S. Savarese. Relmogen: Leveraging motion generation in reinforcement learning for mobile manipulation. *arXiv preprint arXiv:2008.07792*, 2020.

[57] K. Dong, K. Pereida, F. Shkurti, and A. P. Schoellig. Catch the ball: Accurate high-speed motions for mobile manipulators via inverse dynamics learning. In *IROS*, 2020.

[58] K. Blomqvist, M. Breyer, A. Cramariuc, J. Förster, M. Grinvald, F. Tschopp, J. J. Chung, L. Ott, J. Nieto, and R. Siegwart. Go fetch: Mobile manipulation in unstructured environments. *ICRA Workshop*, 2020.

[59] S. Kuindersma, R. Deits, M. Fallon, A. Valenzuela, H. Dai, F. Permenter, T. Koolen, P. Marion, and R. Tedrake. Optimization-based locomotion planning, estimation, and control design for the atlas humanoid robot. *Autonomous robots*, 2016.

[60] S. Feng, E. Whitman, X. Xinjilefu, and C. G. Atkeson. Optimization based full body control for the atlas robot. In *International Conference on Humanoid Robots*, 2014.

[61] J. Chestnutt, M. Lau, G. Cheung, J. Kuffner, J. Hodgins, and T. Kanade. Footstep planning for the honda asimo humanoid. In *ICRA*, 2005.

[62] N. A. Radford, P. Strawser, K. Hambuchen, J. S. Mehling, W. K. Verdeyen, A. S. Donnan, J. Holley, J. Sanchez, V. Nguyen, L. Bridgwater, et al. Valkyrie: Nasa's first bipedal humanoid robot. *Journal of Field Robotics*, 2015.

[63] A. Agarwal, A. Kumar, J. Malik, and D. Pathak. Legged locomotion in challenging terrains using egocentric vision. In *Conference on Robot Learning (CoRL)*, 2022.