arXiv:2309.05665v2 [cs.RO] 12 Sep 2023

机器人跑酷学习

Ziwen Zhuang*[*13] *ZipengFu*[*2] *Jianren Wang*[4] *Christopher Atkeson*[4] *S¨oren Schwertfeger*[3] *Chelsea Finn*[2] *Hang Zhao*[15]** [1]上海期智研究院, [2]斯坦福大学, [3]上海科技大学, [4]卡内基梅隆大学, [5]清华大学, *项目共同负责人 项目网站：https://robot-parkour.github.io***

图1：我们提出了一种在低成本机器人上学习跑酷技能的框架。我们的基于视觉的端到端跑酷学习系统使机器人能够攀爬高障碍物、跨越大的间隙、在低矮障碍物下方爬行、穿过狭窄缝隙并奔跑。视频可在项目网站上查看。

摘要：跑酷是腿足式运动的一项重大挑战，要求机器人在复杂环境中快速克服各种障碍。现有方法可以通过参考动物数据或复杂奖励，生成多样但无视觉的运动技能，或基于视觉但专门化的技能。然而，自主跑酷要求机器人学习既基于视觉又多样化的可泛化技能，以感知并应对各种场景。在这项工作中，我们提出了一个系统，仅使用简单奖励并且无需任何参考运动数据，即可学习一个单一的、基于视觉的端到端跑酷策略，涵盖多种跑酷技能。我们开发了一种受直接配点法启发的强化学习方法，用于生成跑酷技能，包括攀爬高障碍物、跨越大的间隙、在低矮障碍物下方爬行、穿过狭窄缝隙以及奔跑。我们将这些技能蒸馏为一个单一的基于视觉的跑酷策略，并利用机器人自身的第一视角深度相机将其迁移到四足机器人上。我们证明，我们的系统能够使两款不同的低成本机器人自主选择并执行合适的跑酷技能，以穿越具有挑战性的现实世界环境。

关键词：敏捷运动，视觉运动控制，仿真到现实迁移

1 引言

人类和动物拥有惊人的运动智能。跑酷是许多具备运动智能的生物的典范，它们能够在复杂环境中通过奔跑、攀爬和跳跃来快速移动并克服各种障碍 [1]。这种敏捷的动态运动需要实时的视觉感知和对周围环境的记忆 [2, 3]，紧密

第七届机器人学习会议（CoRL 2023），美国亚特兰大。

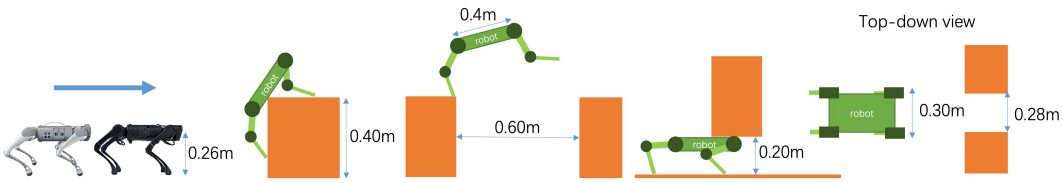

图2：我们展示了我们的系统能够解决的各种高难度障碍，包括攀爬0.40米（1.53倍机器人高度）的高障碍物、跃过0.60米（1.5倍机器人长度）的大沟坎、钻过0.2米（0.76倍机器人高度）的低矮障碍物，以及通过倾斜身体挤过0.28米的狭窄缝隙（该宽度小于机器人宽度）。

感知与行动的耦合 [4, 5]，以及强大的四肢来越过障碍 [6]。机器人运动的一大挑战是构建自主跑酷系统。

波士顿动力公司的Atlas机器人 [7] 已经展示出惊人的跑酷技能。然而，为进行预测控制而对机器人及其周围环境进行建模所需的大量工程工作，以及高昂的硬件成本，使得人们无法在合理预算内复现跑酷行为。最近，基于学习的方法在行走 [8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 12, 21, 22, 23, 24, 25, 26, 27], 、爬楼梯 [20, 28, 29, 30, 31, 32, 33], 、模仿动物 [34, 35, 36, 37, 38, 39] 以及腿部移动操作 [40,41, 42] 方面表现出稳健的性能，这些方法通过在仿真中学习策略并将其迁移到现实世界，避免了许多针对特定机器人建模所需的昂贵工程和设计。我们能否仅使用低成本硬件，利用基于学习的方法来实现机器人跑酷？

机器人跑酷学习面临若干挑战。首先，学习多样化的跑酷技能（例如奔跑、攀爬、跳跃、匍匐、钻缝等）本身就具有挑战性。现有的强化学习工作通过设计包含多项复杂奖励函数的奖励项来引导腿足机器人产生期望行为。通常每种行为都需要手动调整奖励项和超参数；因此，这些工作不足以规模化地生成各种灵活敏捷的跑酷技能。相比之下，直接模仿动物运动捕捉数据的学习方式可以绕开繁琐的奖励设计与调参， [34, 43], 但缺乏以自我为中心的视觉数据和多样化的动物运动捕捉技能，使得机器人无法学习多样化的敏捷技能，也无法通过感知环境条件来自主选择技能。其次，如图2所示，障碍物对于低成本的小型机器人而言可能具有挑战性。第三，除了学习多样化技能这一挑战外，视觉感知在高速运动过程中是动态且滞后的。例如，当机器人以1m/s的速度移动时，0.2秒的信号通信延迟将导致0.2米（7.9英寸）的感知偏差。现有的基于学习的方法尚未展现出有效的高速敏捷运动能力。最后，跑酷会使电机达到最大功率，因此系统中必须包含主动措施来减轻对电机的潜在损害。

本文介绍了一种面向低成本四足机器人的机器人跑酷学习系统，该系统可以执行多种跑酷技能，例如翻越高的障碍物、跨越大的间隙、在低矮障碍物下方爬行、挤过狭窄缝隙以及奔跑。我们的强化学习方法受直接配点法启发，包含两个模拟训练阶段：带软动力学约束的强化学习预训练和带硬动力学约束的强化学习微调。在强化学习预训练阶段，我们使用一种施加软动力学约束的自动课程，允许机器人穿透障碍物。这鼓励机器人逐渐学会克服这些障碍，同时尽可能减少穿透。在强化学习微调阶段，我们强制执行所有动力学约束，并以真实动力学对预训练阶段学到的行为进行微调。在两个阶段中，我们仅使用一个简单的奖励函数，激励机器人在节省机械能的同时向前移动。在学会每一项单独的跑酷技能后，我们使用DAgger [44, 45] 将它们蒸馏为一个基于视觉的单一跑酷策略，该策略仅利用机载感知和计算能力即可部署到足式机器人上。

本文的主要贡献包括：

- 一个用于机器人跑酷学习的开源系统，为研究人员提供训练和部署敏捷运动策略的平台；
- 一种用于克服困难探索问题的两阶段强化学习方法，涉及具有软动力学约束的预训练阶段和具有硬动力学约束的微调阶段；

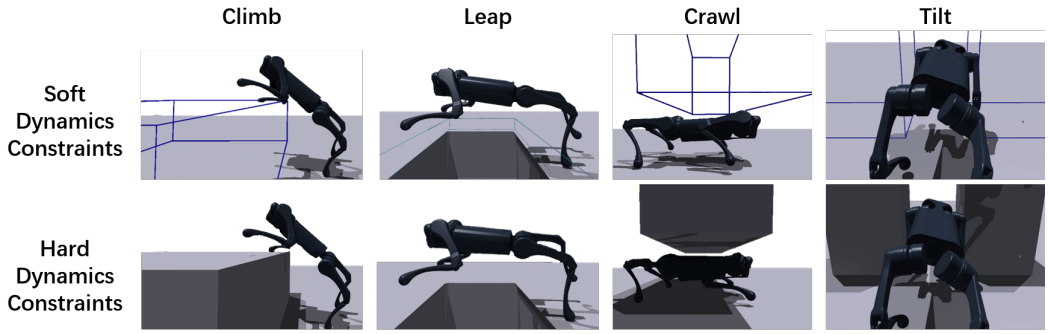

图3：每种技能的软动力学约束与硬动力学约束。在软动力学约束下，障碍物是可穿透的。

• 在仿真和真实世界中的大量实验表明，我们的跑酷策略使低成本四足机器人仅利用机载计算、机载视觉感知和机载动力，即可自主选择并执行适当的跑酷技能，穿越开放世界中具有挑战性的环境，包括攀爬0.40米（1.53倍机器人身高）的高障碍物、跃过0.60米（1.5倍机器人身长）的大间隙、在0.2米（0.76倍机器人身高）的低障碍物下方爬行、通过倾斜穿过0.28米的狭窄缝隙（小于机器人宽度）以及奔跑；

• 泛化到不同机器人，我们证明了我们的系统使用相同的训练流程可以驱动两种不同的机器人：A1和Go1。

2 相关工作

敏捷运动。基于模型的控制已在敏捷运动方面取得了很大成功，例如：MIT Cheetah 机器人和 A1 机器人跳跃越过或登上不同高度的障碍物 [46, 47, 48], , ETH StarlETH 机器人垂直跳跃 [49], , CMU Unified Snake 机器人爬树 [50], , X-RHex 机器人利用尾巴自复位 [51], , ANYmal ALMA 机器人开门 [52], , ATRIAS 机器人走过踏脚石 [53, 54], , Marc Raibert 的单腿跳跃机 [55], , 以及 Boston Dynamics Atlas 的跑酷技能 [7]。近年来，基于学习的方法也展示了多种敏捷运动能力，包括高速奔跑 [56, 16, 57, 35], , 从随机状态重置为站立姿势 [11, 38, 15, 58], , 跳跃 [59, 60, 61], , 爬楼梯 [20, 10, 28, 29, 30, 32,33], , 翻越障碍物 [62], , 在踏脚石上行走 [29],, 后空翻 [63],, 四足机器人用后腿站立 [43], , 开门 [40, 64, 65, 66], , 在部件受损时移动 [67],, 接住飞行物体 [68], , 用尾巴保持平衡 [69], , 踢足球 [70, 71, 72, 73],, 绕杆穿行 [74] , 以及攀爬斜坡 [74]。这些技能大多不依赖视觉，或依赖状态估计，并且针对这些单一技能设计了专门的方法。相比之下，我们构建了一个系统，用于学习一个统一的基于视觉的端到端跑酷策略，以完成多种跑酷技能。

基于视觉的运动。经典模块化方法依赖于解耦的视觉感知和控制流水线，其中高程图 [75, 76, 77, 78, 79, 80, 81], 、可穿越性地图 [82, 83,84, 85]，或状态估计器 [86, 87, 88, 89, 90, 91, 92, 93, 94, 95] 被构建为中间表示，用于下游立足点规划、路径规划和控制 [96, 97, 98, 99, 100,101, 102, 103, 104, 105, 106, 107, 108]。最近，基于端到端学习的方法也将视觉信息纳入运动控制，其中视觉感知通过深度传感 [29, 61, 31], 、高程图 [28, 109, 110, 111, 112], 、激光雷达扫描 [113], 、RGB 图像 [32],、事件相机 [68] 或学习到的神经空间 [30, 33]，执行，但尚无方法展示出有效的高速敏捷运动。

3 机器人跑酷学习系统

我们的目标是构建一个端到端的跑酷系统，该系统直接使用机载原始深度感知和本体感觉来控制低成本机器人的每个关节，以执行各种敏捷的跑酷技能，例如翻越高障碍、跨越宽大间隙、在低矮障碍物下方爬行、挤过狭窄缝隙以及奔跑。与以往针对不同运动技能使用不同方法和训练方案的工作不同，我们旨在自动且系统性地生成这五种跑酷技能。为实现这一目标，我们开发了一种两阶段强化学习方法，该方法

受直接配点法启发，可在同一框架下学习这些跑酷技能。在强化学习预训练阶段，我们通过一个施加软动力学约束的自动课程，允许机器人穿透障碍物。我们鼓励机器人在尽量减少穿透和机械能消耗的同时，逐步学会克服这些障碍。在强化学习微调阶段，我们使用真实动力学对预训练行为进行微调。在这两个阶段，我们仅使用一个简单的奖励函数，激励机器人向前移动，同时节省机械能。在学得每一项跑酷技能后，我们使用 DAgger [44, 45] 将它们蒸馏成一个可部署的、基于视觉的单一跑酷策略。为了在低成本机器人上实现稳健的仿真到现实部署，我们对深度图像采用了几种预处理技术，校准了机载视觉延迟，并实施了主动的电机安全措施。

3.1 通过两阶段 *RL* 进行跑酷技能学习

由于深度图像的渲染成本高昂，且直接基于视觉数据训练 RL 并不总是稳定的，我们利用关于环境的特权视觉信息来帮助 RL 在仿真中生成专门的跑酷技能。特权视觉信息包括机器人当前位置到前方障碍物的距离、障碍物的高度、障碍物的宽度，以及表示四类障碍物的 4 维 one-hot 分类向量。我们将每一种专门的

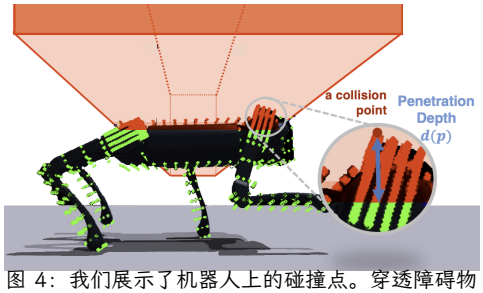

图 4：我们展示了机器人上的碰撞点。穿透障碍物的碰撞点以红色显示。

技能策略被建模为门控循环神经网络（GRU [114]）。除循环隐状态外，策略的输入还包括本体感觉 $s_t^{\text{proprio}} \in \mathbb{R}^{29}$（横滚角、俯仰角、基座角速度、关节位置和速度）、上一动作 $a_{t-1} \in \mathbb{R}^{12}$、特权视觉信息 e_t^{vis} 和特权物理信息 e_t^{phy}。我们采用与先前工作 [8, 10] 类似的方法来采样物理属性，如地形摩擦、机器人基座质心、电机强度等，以实现从仿真到真实世界的领域自适应。策略输出目标关节位置 $a_t \in \mathbb{R}^{12}$。

我们使用相同的奖励结构，分别在如图 3 所示的对应地形上训练所有专项技能策略 π_{climb}, π_{leap}, π_{crawl}, π_{tilt}, π_{run}。我们采用 [35] 中最小化机械能的公式，推导出一个适用于生成所有自然动作技能的通用技能奖励 r_{skill}，该奖励仅由三部分组成：前向奖励 r_{forward}、能量奖励 r_{energy} 和存活奖励 r_{alive}：

$$r_{\text{skill}} = r_{\text{forward}} + r_{\text{energy}} + r_{\text{alive}},$$

其中

$$r_{\text{forward}} = -\alpha_1 * |v_x - v_x^{\text{target}}| - \alpha_2 * |v_y|^2 + \alpha_3 * e^{-|\omega_{\text{yaw}}|},$$
$$r_{\text{energy}} = -\alpha_4 * \sum_{j \in \text{joints}} |\tau_j \dot{q}_j|^2, \quad r_{\text{alive}} = 2.$$

在每个时间步测量以下变量：v_x 为前向机体线速度，v_x^{target} 为目标速度，v_y 为侧向机体线速度，ω_{yaw} 为机体偏航角速度，τ_j 为关节 j 处的力矩，ω_{yaw} 为关节 j 处的关节速度；α 为超参数。我们将所有技能的目标速度设为约 1 m/s。我们对每个关节的电机功率取二次方，以同时降低所有关节电机功率的平均值和方差。所有超参数详见补充材料。

基于软动力学约束的RL预训练。如图2所示，跑酷技能的困难学习环境使通用RL算法难以有效找到能够克服这些挑战性障碍的策略。受直接配点法与软约束的启发，我们提出使用软动力学

技能	障碍物属性	训练范围 ($[l_{\text{easy}}, l_{\text{hard}}]$)	测试范围 ($[l_{\text{easy}}, l_{\text{hard}}]$)
攀爬	障碍物高度	[0.2, 0.45]	[0.25, 0.5]
Leap	间隙长度	[0.2, 0.8]	[0.3, 0.9]
爬行	净空	[0.32, 0.22]	[0.3, 0.2]
Tilt	路径宽度	[0.32, 0.28]	[0.3, 0.26]

表1：训练期间每种技能障碍物属性的范围，以米为单位。

约束来解决这些困难的探索问题。如图3所示，我们将障碍物设置为可穿透的，从而使机器人可以通过直接穿过障碍物来违反模拟中的物理动力学，

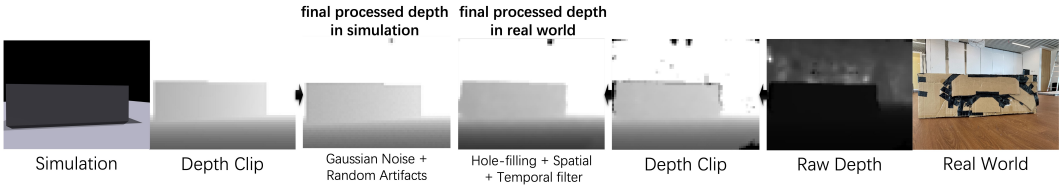

图 5：我们通过应用预处理技术弥合了仿真与真实世界之间的视觉差距。我们在仿真中使用深度裁剪、高斯噪声和随机伪影，在真实世界中使用深度裁剪与空洞填充、空间和时间滤波器。

这些障碍物，而不会因为真实动力学（即硬动力学约束）下强化学习训练的局部极小值而卡在障碍物附近。与直接配点法的拉格朗日公式类似， [115], 我们开发了一个穿透奖励 $r_{\text{penetrate}}$ ，以逐步施加动力学约束，并设计了一个自适应调整障碍物难度的自动课程。这一想法也已在机器人操作中得到了探索 [116, 117]。如图4所示，为了衡量动力学约束的违反程度，我们在机器人的碰撞体中采样碰撞点，以测量穿透的体积和深度。由于机器人的髋部和肩部包含所有电机，我们在这些区域周围采样更多碰撞点，以施加更强的动力学约束，从而鼓励这些脆弱身体部位在现实世界中减少碰撞。将碰撞体上的一个碰撞点记为 p，将 p 是否违反软动力学约束的指示函数记为 $\mathbb{1}[p]$，并将 p 到被穿透障碍物表面的距离记为 $d(p)$。穿透体积可以通过所有碰撞点上 $\mathbb{1}[p]$ 的总和来近似，平均穿透深度可以通过 $d(p)$ 的总和来近似。在图4中，违反软动力学约束的碰撞点 ($\mathbb{1}[p] = 1$) 为红色，而满足 $\mathbb{1}[p] = 0$ 的碰撞点为绿色。具体地，穿透奖励为

$$r_{\text{penetrate}} = -\sum_{p} (\alpha_5 * \mathbb{1}[p] + \alpha_6 * d(p)) * v_x,$$

其中 α_5 和 α_6 是两个固定常数。我们将穿透体积和穿透深度与前向基础速度 v_x 相乘，以防止机器人通过快速穿过障碍物来利用穿透奖励，从而避免随时间累积的高额惩罚。此外，我们实现了一个自动课程，它会在重置后根据仿真中并行模拟的每个机器人的表现，自适应地调整障碍物的难度。我们首先根据机器人在重置前上一个回合中平均的穿透奖励来计算其表现。如果穿透奖励超过阈值，我们将机器人将要面对的障碍物的难度分数 s 增加一个单位（0.05）；如果更低，则将其减少一个单位。每个机器人从难度分数 0 开始，最大难度分数为 1。我们根据机器人的难度分数，通过 $(1 - s) * l_{\text{easy}} + s * l_{\text{hard}}$ 来设置其障碍物属性，其中 l_{easy} 和 l_{hard} 是不同跑酷技能对应的障碍物属性范围的两个极限（见表 1）。我们使用 PPO [118]，以通用技能奖励与穿透奖励之和 $r_{\text{skill}} + r_{\text{penetrate}}$ 作为奖励，在软动力学约束下预训练专用跑酷技能。

RL 在硬动力学约束下的微调。在 RL 预训练阶段接近收敛后，我们针对现实的硬动力学约束（如图 3 所示）对每个专门的跑酷技能策略进行微调；因此，在 RL 的第二阶段，机器人与障碍物之间不可能发生穿透。我们仅使用通用技能奖励 r_{skill}，通过 PPO 对专门技能进行微调。在微调过程中，我们从表 1 所列范围内随机采样障碍物属性。由于跑步技能是在没有障碍物的地形上训练的，我们直接以硬动力学约束训练跑步技能，并跳过带有软动力学约束的 RL 预训练阶段。

3.2 通过蒸馏学习单一跑酷策略

所学习到的专项跑酷技能是五个策略，它们同时使用特权视觉信息 e_t^{vis} 和特权物理信息 e_t^{phy} 。然而，真值特权信息仅在仿真中可用，在现实世界中不可用。此外，每个专项策略只能执行一种技能，无法基于对环境的视觉感知自主执行并在不同跑酷技能之间切换。我们提出使用 DAgger [44, 45] 来蒸馏

	成功率（%）↑					平均距离（m）↑				
	攀爬	Leap	爬行	Tilt	Run	攀爬	Leap	爬行	Tilt	Run
盲	0	0	13	0	100	1.53	1.86	2.01	1.62	3.6
MLP	0	1	63	43	100	1.59	1.74	3.27	2.31	3.6
无蒸馏	0	0	73	0	100	1.57	1.75	2.76	1.86	3.6
RMA [8]	-	-	-	**74**	-	-	-	-	**2.7**	-
我们的（跑酷策略）	**86**	**80**	**100**	73	100	**2.37**	**3.05**	**3.6**	2.68	3.6
无Soft Dyn的专家策略	0	0	93	86	100	1.54	1.73	3.58	1.73	3.6
专家策略	95	82	100	100	100	3.60	3.59	3.6	2.78	3.6

表2：我们在最大距离为3.6米的仿真中测试了我们的方法，并与多个基线和消融实验进行比较。我们衡量了每个技能在100次试验和3个随机种子上的平均成功率与平均距离。我们的跑酷策略仅使用现实世界可用的传感器就表现出最佳性能。我们在测试环境上进行了评估，这些环境中的障碍物属性比表1所示训练环境中的障碍物属性更难。

一个基于视觉的跑酷策略 π_{parkour}，利用来自五个专用技能策略 $\pi_{\text{climb}}, \pi_{\text{leap}}, \pi_{\text{crawl}}, \pi_{\text{tilt}}, \pi_{\text{run}}$ 的机载传感信息。我们从表1中随机采样障碍物的类型和属性，以生成一个由40条跑道组成、每条跑道上有20个障碍物的仿真地形。由于我们完全知道与每个状态 s_t 相关的障碍物类型，我们可以分配相应的专用技能策略 $\pi_{s_t}^{\text{specialized}}$ 来教导跑酷策略在某个状态下如何行动。例如，对于高障碍物，我们分配攀爬策略 π_{climb} 来监督跑酷策略。我们将策略参数化为 GRU。除循环潜在状态外，输入包括本体感觉 s_t^{proprio}、上一动作 a_{t-1} 以及由小型 CNN 处理的深度图像的潜在嵌入 I_t^{depth}。蒸馏目标为

$$\arg\min_{\theta_{\text{parkour}}} \mathbb{E}_{s_t, a_t \sim \pi_{\text{parkour}}, sim} \left[D\left(\pi_{\text{parkour}}\left(s_t^{\text{proprio}}, a_{t-1}, I_t^{\text{depth}} \right), \pi_{s_t}^{\text{specialized}}\left(s_t^{\text{proprio}}, a_{t-1}, e_t^{\text{vis}}, e_t^{\text{phy}} \right) \right) \right],$$

其中 θ_{parkour} 是跑酷策略的网络参数，sim 是具有硬动力学约束的模拟器，D 是散度函数，对于以 tanh 作为最后一层的策略网络，该散度函数是二元交叉熵损失。策略 π_{parkour} 和 $\pi_{s_t}^{\text{specialized}}$ 均是有状态的。关于跑酷策略网络的更多细节见补充材料。

3.3 仿真到现实的迁移与部署

尽管第3.2节中的蒸馏训练能够弥合机器人在物理动力学属性（如地形摩擦和质量属性）方面的仿真到现实差距 [8, 10],，我们仍然需要解决仿真中渲染的深度图像与现实世界中深度相机拍摄的机载深度图像之间在视觉外观上的仿真到现实差距。如图5所示，我们对原始渲染深度图像和原始真实世界深度图像均应用预处理技术。我们对原始渲染深度图像应用深度裁剪、像素级高斯噪声和随机伪影，并对原始真实世界深度图像应用深度裁剪、空洞填充、空间平滑和时间平滑。

仿真和现实世界中的深度图像分辨率均为48 * 64。由于机载计算能力有限，机载深度图像的刷新率为10Hz。我们的跑酷策略在仿真和现实世界中均以50Hz运行，以实现敏捷的运动技能，并异步获取由小型CNN处理的深度图像的最新潜在嵌入。策略的输出动作是目标关节位置，通过 $K_p = 50$ 和 $K_d = 1$的PD控制器以约1000Hz的频率转换为力矩。为确保安全部署，我们通过裁剪目标关节位置来施加25Nm的力矩限制：clip(q^{target}, $(K_d * \dot{q} - 25)/K_p + q$, $(K_d * \dot{q} + 25)/K_p + q$)。

4 实验结果

机器人与仿真设置。我们使用 IsaacGym [119] 作为模拟器来训练所有策略。为了训练专用的跑酷技能，我们构建了大规模仿真环境，包含 40 条轨道，每条轨道上有 20 个障碍物。每条轨道上的障碍物根据表 1 中的障碍物属性范围呈线性递增难度。我们使用 Unitree A1 和 Unitree Go1，它们配备了 Nvidia Jetson NX 进行机载计算，并使用 Intel RealSense D435 进行机载视觉感知。更多细节见补充材料。

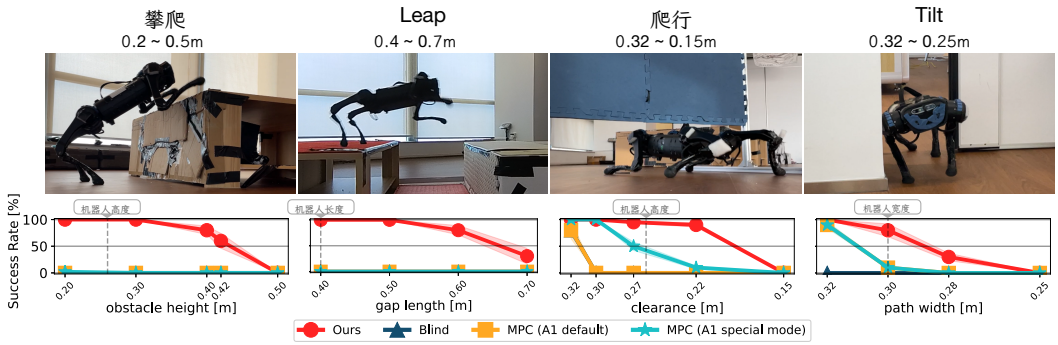

图6：真实世界室内定量实验。与盲策略和内置MPC控制器相比，我们的跑酷策略能够取得最佳性能。我们以A1特殊模式控制MPC，通过遥操作分别使机器人在爬行时降低身体、在倾斜时倾斜身体。

基线与消融实验。我们将我们的跑酷策略与多个基线和消融实验进行比较。基线包括 Blind、RND [120], MLP 和 RMA [8]。消融实验包括 No Distill、Oracles w/o Soft Dyn。我们还加入了 Oracles，即基于仿真中特权信息训练的专用跑酷技能，以使比较更加完整。

- 盲策略：一种从专门技能中蒸馏得到的盲跑酷策略基线，通过将深度图像 I深度设为零来实现。
- RND：一种基于前向预测误差提供奖励加成的RL探索基线方法，用于训练专用技能。我们在不使用基于软动力学约束的RL预训练的情况下训练它。
- MLP：一种从专用技能中蒸馏得到的MLP跑酷策略基线。它不使用GRU，而是在当前时间步仅利用深度图像、本体感觉和上一动作，不依赖任何记忆来输出动作。
- RMA：一种域自适应基线方法，将跑酷策略蒸馏到环境外在变量的潜在空间中，而非动作空间。
- No Distill：一种消融实验，使用PPO并结合我们的两阶段RL方法直接训练带GRU的基于视觉的跑酷策略，但跳过蒸馏阶段。
- Oracles w/o SoftDyn：一种消融实验，使用特权信息并在硬动力学约束下直接训练专用技能策略。
- Oracles (w/ Soft Dyn)：我们的专用技能策略，利用特权信息并通过我们的两阶段RL方法进行训练。

4.1 模拟实验

视觉对于学习跑酷至关重要。我们将Blind基线与我们的方法进行了比较。如表2所示，在没有深度感知且仅依赖本体感觉的情况下，蒸馏得到的盲策略无法完成任何攀爬、跳跃或倾斜试验，只能在爬行任务上达到13%的成功率。这是意料之中的，因为视觉能够感知障碍物的属性，并在机器人接近障碍物时为其做好执行敏捷动作的准备。

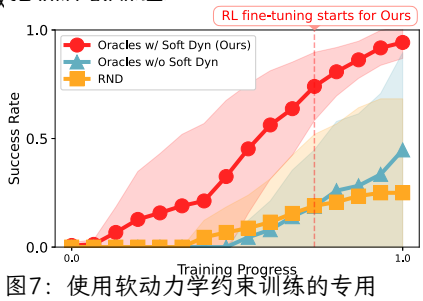

图7：使用软动力学约束训练的专用oracle与基线方法的比较（对所有技能和三次试验取平均）。

带有软动力学约束的RL预训练使跑酷技能的学习成为可能。我们比较了RND、无软动力学约束的Oracles（Oracles w/o Soft Dyn）以及我们的方法（带软动力学约束的Oracles，Oracles w/ Soft Dyn），所有这些方法均在没有蒸馏阶段的情况下使用特权信息进行训练。我们旨在验证，我们提出的带有软动力学约束的RL预训练方法能够实现高效探索。在图7中，我们测量了每种方法在所有需要探索的跑酷技能（包括攀爬、跳跃、爬行和倾斜）上，对100次试验和所有技能取平均后的成功率。我们对每种方法使用三个随机种子进行训练，以测量标准差。我们的

使用带有软动态约束的RL预训练方法可以实现快得多的学习进度，并达到约95%的更好最终成功率。我们注意到，RND在需要精细操作（例如爬过狭窄缝隙）的场景中难以学习到有意义的行为，因为它倾向于到达那些未来状态难以预测的状态。RND和Oracles均没有

Soft Dyn无法在攀登和跳跃这两种最具挑战性的跑酷技能上取得任何学习进展。更多分别显示每种技能成功率的图见补充材料。
循环网络使需要记忆的跑酷技能成为可能。我们将 MLP 基线与我们的方法进行比较，后者使用 GRU 参数化基于视觉的跑酷策略。如表 2 所示，MLP 基线无法学习攀爬和跳跃技能，并且在爬行和倾斜任务上表现也低得多。攀爬和跳跃都需要机器人对过去的视觉感知保持短期记忆。例如，在攀爬过程中，当机器人的前腿搭在障碍物上时，它仍然需要记忆过去深度图像中捕获的障碍物空间尺寸，以控制后腿完成攀爬。

蒸馏对 Sim2Real 很有效。我们将 RMA 基线和 No Distill 基线与我们的方法进行比较。尽管 RMA 在其训练的单一技能（即倾斜）上可以达到类似的性能，但 RMA 固定了处理骨干 GRU 潜在嵌入的 MLP 网络参数，并将这些参数直接从专门技能复制到蒸馏后的策略中。因此，它无法将多个具有不同 MLP 参数的专门技能策略蒸馏成一个跑酷策略。No Distill 则因在没有特权信息的情况下直接由视觉观测进行训练的复杂性，无法学习攀爬、跳跃和倾斜。

4.2 真实世界实验

攀爬过程中的涌现性重试行为。我们的跑酷策略在现实世界中表现出涌现性的重试行为。当机器人试图翻越一个高障碍物但在第一次尝试中失败时，它会将自己推离障碍物，以确保后续尝试有足够的助跑空间。尽管我们没有编程实现这种重试行为，但它通过简单的奖励从学习过程中很好地涌现出来。这种行为在仿真中也被观察到。

室内定量实验。如图1所示，我们在一个由爬行、攀爬和跳跃依次组成的构造跑酷地形上测试了我们的跑酷策略。我们还在真实世界的A1机器人上进行了定量室内实验。在图6中，我们将基于视觉的跑酷策略与Blind、MPC（A1默认控制器）和MPC（A1特殊模式）进行了比较。我们展示了每种方法在不同难度下每个技能的成功率，每个技能各测试10次。我们通过修改关键障碍物属性来改变技能难度，例如攀爬的障碍物高度和跳跃的间隙长度。在A1特殊模式中，我们直接远程操作机器人来改变其状态，例如在爬行时降低身体。我们观察到，我们的跑酷策略能使机器人以80%的成功率攀爬高达0.40米（1.53倍机器人身高）的障碍物，以80%的成功率跨越最大0.60米（1.5倍机器人身长）的间隙，以90%的成功率在低至0.2米（0.76倍机器人身高）的障碍物下爬行，以及通过倾斜身体挤过0.28米的狭窄缝隙（小于机器人宽度）。我们的方法在所有技能上均表现最佳。有关室内实验视频，请参阅我们的项目网站。

户外实验。如图1所示，我们在各种户外环境中测试了我们的机器人。我们观察到，由我们的跑酷策略控制的机器人能够完成一系列灵活的跑酷技能。它可以跃过河边两个不相连、间距0.6米的石凳。它可以连续攀爬多级每级高0.42米的台阶。它可以钻过露营车底部，同时应对湿滑的草地地形。更多户外实验视频请参阅我们的项目网站。

5 结论、局限性与未来方向

我们提出了一套适用于低成本机器人的跑酷学习系统。我们提出了一种两阶段强化学习方法，以克服学习跑酷技能过程中遇到的困难探索问题。我们还在仿真和真实世界中广泛测试了我们的系统，并表明该系统在具有挑战性的室内外环境中，对各种高难度跑酷技能都表现出稳健的性能。然而，当前系统需要人工构建仿真环境。因此，只有将具有不同障碍物和外观的新环境添加到仿真中，才能学习新技能。这降低了新技能自动学习的程度。未来，我们希望利用三维视觉和图形学的最新进展，从大规模真实世界数据中自动构建多样化的仿真环境。我们还将研究如何直接从包含语义信息的RGB图像而非深度图像训练敏捷移动技能。

致谢
我们要感谢 Wenxuan Zhou 及其 Emergent Extrinsic Dexterity 项目 [116]，该项目启发了我们允许穿透的训练流程。我们还要感谢 Xiaozhu Lin、Wenqing Jiang、Fan Nie、Ruihan Yang、Xuxin Chen、Tony Z. Zhao 以及 Unitree Robotics（Yunguo Cui）在真实世界实验中的帮助。Zipeng Fu 得到了斯坦福研究生奖学金（Pierre and Christine Lamond Fellowship）的资助。本项目得到上海期智研究院和 ONR 基金 N00014-20-1-2675 的支持。

参考文献

[1] Merriam Webster：跑酷（Parkour）。URL https://www.merriam-webster.com/dictionary/ parkour。[2] A. E. Patla。理解视觉在人体运动控制中的作用。Gait & posture，1997。[3] A. A. Mohagheghi、R. Moraes和A. E. Patla。远距离和在线视觉信息对运动过程中接近阶段和跨越障碍物控制的影响。Experimental brain research，2004。[4] J. M. Loomis、J. A. Da Silva、N. Fujita和S. S. Fukusima。视觉空间知觉与视觉引导行为。Journal of experimental psychology: Human Perception and Performance，1992。[5] J. S. Matthis和B. R. Fajen。在复杂地形上行走时脚部放置的视觉控制。Journal of experimental psychology: human perception and performance，2014。[6] D. L. Puddle和P. S. Maulder。与跑酷和传统落地技术相关的地面反作用力和加载速率。Journal of sports science & medicine，2013。[7] Boston Dynamics：Atlas。URL https://www.bostondynamics.com/atlas。[8] A. Kumar、Z. Fu、D. Pathak和J. Malik。RMA：腿式机器人的快速运动适应。发表于RSS，2021。[9] J. Tan、T. Zhang、E. Coumans、A. Iscen、Y. Bai、D. Hafner、S. Bohez和V. Vanhoucke。从仿真到现实：学习四足机器人的敏捷运动。发表于RSS，2018。[10] J. Lee、J. Hwangbo、L. Wellhausen、V. Koltun和M. Hutter。学习在复杂地形上的四足运动。Science Robotics，2020年10月。[11] J. Hwangbo、J. Lee、A. Dosovitskiy、D. Bellicoso、V. Tsounis、V. Koltun和M. Hutter。学习腿式机器人的敏捷和动态运动技能。Science Robotics，2019。[12] Z. Xie、X. Da、M. van de Panne、B. Babich和A. Garg。动态随机化再探：四足运动案例研究。发表于ICRA，2021。[13] X. Song、Y. Yang、K. Choromanski、K. Caluwaerts、W. Gao、C. Finn和J. Tan。通过进化元学习实现快速自适应的腿式机器人。发表于IROS，2020。[14] T. Haarnoja、S. Ha、A. Zhou、J. Tan、G. Tucker和S. Levine。通过深度强化学习学会行走。arXiv预印本 arXiv:1812.11103，2018。[15] L. Smith、J. C. Kew、X. B. Peng、S. Ha、J. Tan和S. Levine。持续学习的腿式机器人：在现实世界中微调运动策略。发表于ICRA，2022。[16] G. B. Margolis、G. Yang、K. Paigwar、T. Chen和P. Agrawal。通过强化学习实现快速运动。RSS，2022。[17] R. Yang、M. Zhang、N. Hansen、H. Xu和X. Wang。利用跨模态Transformer端到端学习视觉引导的四足运动。发表于ICLR，2022。

[18] W. Yu、V. C. V. Kumar、G. Turk和C. K. Liu。双足运动的仿真到现实迁移。发表于IROS，2019。[19] Z. Li、X. Cheng、X. B. Peng、P. Abbeel、S. Levine、G. Berseth和K. Sreenath。用于双足机器人鲁棒参数化运动控制的强化学习。发表于ICRA，2021。[20] J. Siekmann、K. Green、J. Warila、A. Fern和J. Hurst。基于仿真到现实强化学习的盲态双足楼梯通行。arXiv预印本 arXiv:2105.08328，2021。[21] S. Ha、P. Xu、Z. Tan、S. Levine和J. Tan。以最少的人力在现实世界中学习行走。arXiv预印本 arXiv:2002.08550，2020。[22] X. Da、Z. Xie、D. Hoeller、B. Boots、A. Anandkumar、Y. Zhu、B. Babich和A. Garg。学习用于鲁棒、高效腿式运动的接触自适应控制器。arXiv预印本 arXiv:2009.10019，2020。[23] Z. Fu、A. Kumar、A. Agarwal、H. Qi、J. Malik和D. Pathak。融合视觉与本体感知的腿式机器人导航。发表于CVPR，2022。[24] S. Schmidgall和J. Hays。突触运动适应：脉冲神经网络中自适应机器人控制的三因子学习规则。arXiv预印本 arXiv:2306.01906，2023。[25] S. Kareer、N. Yokoyama、D. Batra、S. Ha和J. Truong。Vinl：跨越障碍物的视觉导航与运动。ICRA，2023。[26] M. Seo、R. Gupta、Y. Zhu、A. Skoutnev、L. Sentis和Y. Zhu。通过转向学习行走：动态环境中的感知四足运动。ICRA，2023。[27] J. Truong、A. Zitkovich、S. Chernova、D. Batra、T. Zhang、J. Tan和W. Yu。Indoorsim-to-outdoorreal：无需任何室外经验即可学习在室外导航。arXiv预印本 arXiv:2305.01098，2023。[28] T. Miki、J. Lee、J. Hwangbo、L. Wellhausen、V. Koltun和M. Hutter。学习四足机器人在野外环境中的鲁棒感知运动。Science Robotics，2022年1月。[29] A. Agarwal、A. Kumar、J. Malik和D. Pathak。利用自我中心视觉在复杂地形中进行腿式运动。发表于Conference on Robot Learning (CoRL)，2022。[30] R. Yang、G. Yang和X. Wang。用于视觉运动控制的神经体积记忆。CVPR，2023。[31] W. Yu、D. Jain、A. Escontrela、A. Iscen、P. Xu、E. Coumans、S. Ha、J. Tan和T. Zhang。Visual-locomotion：利用视觉在复杂地形上学习行走。发表于5th Annual Conference on Robot Learning，2021。[32] A. Loquercio、A. Kumar和J. Malik。使用跨模态监督学习视觉运动。arXiv预印本 arXiv:2211.03785，2022。[33] D. Hoeller、N. Rudin、C. Choy、A. Anandkumar和M. Hutter。用于结构化地形运动的神经场景表示。IEEE Robotics and Automation Letters，2022。[34] X. B. Peng、E. Coumans、T. Zhang、T.-W. E. Lee、J. Tan和S. Levine。通过模仿动物学习敏捷的机器人运动技能。发表于RSS，2020。[35] Z. Fu、A. Kumar、J. Malik和D. Pathak。最小化能量消耗导致腿式机器人步态的出现。发表于CoRL，2021。[36] T. Li、J. Won、S. Ha和A. Rai。用于敏捷、多样且可泛化四足运动的基于模型的运动模仿。arXiv预印本 arXiv:2109.13362，2021。

[37] Y. Yang、T. Zhang、E. Coumans、J. Tan 和 B. Boots. 通过习得的步态转换实现快速高效的运动。收录于 CoRL，2021。[38] C. Yang、K. Yuan、Q. Zhu、W. Yu 和 Z. Li. 面向自适应腿部运动的多专家学习。《科学•机器人学》，2020。[39] D. Kang、J. Cheng、M. Zamora、F. Zargarbashi 和 S. Coros. Rl+ 基于模型的控制：利用按需最优控制学习多功能腿部运动。arXiv 预印本 arXiv:2305.17842，2023。[40] Z. Fu、X. Cheng 和 D. Pathak. 深度全身控制：学习用于操作和运动的统一策略。收录于机器人学习大会，2022。[41] Y. Ma、F. Farshidian、T. Miki、J. Lee 和 M. Hutter. 将基于学习的运动策略与基于模型的操纵相结合，用于腿式移动机械臂。《IEEE 机器人与自动化快报》，2022。[42] N. Yokoyama、A. W. Clegg、E. Undersander、S. Ha、D. Batra 和 A. Rai. 机器人移动操作的自适应技能协调。arXiv 预印本 arXiv:2304.00410，2023。[43] L. Smith、J. C. Kew、T. Li、L. Luu、X. B. Peng、S. Ha、J. Tan 和 S. Levine. 通过迁移经验学习和适应敏捷运动技能。RSS，2023。[44] S. Ross、G. Gordon 和 D. Bagnell. 将模仿学习和结构化预测归约为无遗憾在线学习。收录于第十四届国际人工智能与统计会议论文集。JMLR 研讨会与会议论文集，2011。[45] D. Chen、B. Zhou、V. Koltun 和 P. Kr¨ahenb¨uhl. 通过作弊学习。收录于机器人学习大会，2020。[46] H.-W. Park、P. M. Wensing、S. Kim 等. 高速四足机器人跨越障碍的自主奔跑跳跃在线规划。RSS，2015。[47] Q. Nguyen、M. J. Powell、B. Katz、J. Di Carlo 和 S. Kim. MIT Cheetah 3 机器人上的优化跳跃。收录于2019年国际机器人与自动化会议（ICRA），2019。[48] C. Nguyen、L. Bao 和 Q. Nguyen. 基于轨迹优化和模型预测控制的腿式机器人在垫脚石上的连续跳跃。收录于2022年IEEE第61届决策与控制会议（CDC），第93–99页。IEEE，2022。[49] C. Gehring、S. Coros、M. Hutter、C. D. Bellicoso、H. Heijnen、R. Diethelm、M. Bloesch、P. Fankhauser、J. Hwangbo、M. Hoepflinger 等. 熟能生巧：一种基于优化的四足机器人敏捷运动控制方法。《IEEE 机器人与自动化杂志》，2016。[50] C. Wright、A. Buchan、B. Brown、J. Geist、M. Schwerin、D. Rollinson、M. Tesch 和 H. Choset. 统一模块化蛇形机器人的设计与架构。收录于2012年IEEE国际机器人与自动化会议，2012。[51] A. M. Johnson、T. Libby、E. Chang-Siu、M. Tomizuka、R. J. Full 和 D. E. Koditschek. 尾部辅助的动态自复位。收录于《自适应移动机器人学》。2012。[52] C. D. Bellicoso、K. Kr¨amer、M. St¨auble、D. Sako、F. Jenelten、M. Bjelonic 和 M. Hutter. Alma-面向力矩可控机器人的关节式运动与操作。收录于2019年国际机器人与自动化会议（ICRA），第8477–8483页。IEEE，2019。[53] Q. Nguyen、A. Agrawal、X. Da、W. C. Martin、H. Geyer、J. W. Grizzle 和 K. Sreenath. 在随机变化的离散地形上利用单步预观进行动态行走。收录于机器人学：科学与系统会议，2017。

[54] R. Antonova、A. Rai 和 C. G. Atkeson. 用于优化运动控制器的深度核方法。收录于机器人学习大会，2017。[55] M. H. Raibert、H. B. Brown Jr 和 M. Chepponis. 使用三维单腿跳跃机器人进行平衡实验。《国际机器人研究杂志》，1984。[56] Cassie 创下一项吉尼斯世界纪录。URL https://agilityrobotics.com/news/2022/cassie-sets-a-guinness-world-record。[57] G. Ji、J. Mun、H. Kim 和 J. Hwangbo. 控制策略与状态估计器的联合训练，用于动态且稳健的腿部运动。《IEEE 机器人与自动化快报》，2022。[58] Y. Ma、F. Farshidian 和 M. Hutter. 学习机械臂辅助的腿式移动机械臂跌倒损伤减轻与恢复。arXiv 预印本 arXiv:2303.05486，2023。[59] Z. Li、X. B. Peng、P. Abbeel、S. Levine、G. Berseth 和 K. Sreenath. 通过多任务强化学习实现稳健且多功能双足跳跃控制。arXiv 预印本 arXiv:2302.09450，2023。[60] Y. Yang、X. Meng、W. Yu、T. Zhang、J. Tan 和 B. Boots. 使用学习到的动作残差进行连续多功能跳跃。L4DC，2023。[61] G. B. Margolis、T. Chen、K. Paigwar、X. Fu、D. Kim、S. Kim 和 P. Agrawal. 从像素中学习跳跃。CoRL，2021。[62] N. Rudin、D. Hoeller、M. Bjelonic 和 M. Hutter. 通过端到端学习运动与局部导航获得高级技能。收录于2022年IEEE/RSJ国际智能机器人与系统大会（IROS），2022。[63] C. Li、M. Vlastelica、S. Blaes、J. Frey、F. Grimminger 和 G. Martius. 通过对粗略的部分演示进行对抗式模仿来学习敏捷技能。收录于机器人学习大会，2022。[64] X. Cheng、A. Kumar 和 D. Pathak. 腿作为机械臂：将四足机器人的敏捷性推向运动之外。ICRA，2023。[65] E. Arcari、M. V. Minniti、A. Scampicchio、A. Carron、F. Farshidian、M. Hutter 和 M. N. Zeilinger. 用于机器人移动操作的贝叶斯多任务学习模型预测控制。《IEEE 机器人与自动化快报》，2023。[66] H. Ito、K. Yamamoto、H. Mori 和 T. Ogata. 基于具身预测模型的高效多任务学习，用于全身控制下的开门与进入。《科学•机器人学》，2022。[67] A. Nagabandi、I. Clavera、S. Liu、R. S. Fearing、P. Abbeel、S. Levine 和 C. Finn. 通过元强化学习在动态真实世界环境中学会适应。ICLR，2019。[68] B. Forrai、T. Miki、D. Gehrig、M. Hutter 和 D. Scaramuzza. 使用四足机器人进行基于事件的敏捷物体捕捉。ICRA，2023。[69] H. Huang、A. Loquercio、A. Kumar、N. Thakkar、K. Goldberg 和 J. Malik. 不仅仅是手臂：将机械臂用作尾巴以增强腿部运动的稳定性。arXiv 预印本 arXiv:2305.01648，2023。[70] T. Haarnoja、B. Moran、G. Lever、S. H. Huang、D. Tirumala、M. Wulfmeier、J. Humplik、S. Tunyasuvunakool、N. Y. Siegel、R. Hafner 等. 利用深度强化学习为双足机器人学习敏捷足球技能。arXiv 预印本 arXiv:2304.13653，2023。[71] Y. Ji、G. B. Margolis 和 P. Agrawal. Dribblebot：真实环境中的动态腿部操作。arXiv

[72] X. Huang、Z. Li、Y. Xiang、Y. Ni、Y. Chi、Y. Li、L. Yang、X. B. Peng 和 K. Sreenath。利用强化学习创建动态四足机器人守门员。arXiv 预印本 arXiv:2210.04435，2022年。[73] Y. Ji、Z. Li、Y. Sun、X. B. Peng、S. Levine、G. Berseth 和 K. Sreenath。使用四足机器人实现精准足球射门技能的分层强化学习。见2022年IEEE/RSJ智能机器人与系统国际会议（IROS），2022年。[74] K. Caluwaerts、A. Iscen、J. C. Kew、W. Yu、T. Zhang、D. Freeman、K.-H. Lee、L. Lee、S. Saliceti、V. Zhuang 等。Barkour：用四足机器人对动物级敏捷性进行基准测试。arXiv 预印本 arXiv:2305.14654，2023年。[75] P. Fankhauser、M. Bloesch 和 M. Hutter。定位不确定情况下移动机器人的概率地形建图。IEEE机器人与自动化快报，2018年。[76] I.-S. Kweon、M. Hebert、E. Krotkov 和 T. Kanade。漫游行星探测器的地形建图。见IEEE国际机器人与自动化会议，1989年。[77] I.-S. Kweon 和 T. Kanade。基于多传感器数据的高分辨率地形图。IEEE模式分析与机器智能汇刊，1992年。[78] A. Kleiner 和 C. Dornhege。城市搜救场景中的实时定位与高程建图。现场机器人学杂志，2007年。[79] S. Gangapurwala、M. Geisert、R. Orsolino、M. Fallon 和 I. Havoutis。利用深度强化学习实现四足运动的实时轨迹自适应。见2021年IEEE国际机器人与自动化会议（ICRA），2021年。[80] D. Belter、P. Łabcki 和 P. Skrzypczy´nski。从稀疏且不确定的多传感器数据估计地形高程图。见2012年IEEE国际机器人与仿生学会议（ROBIO），2012年。[81] P. Fankhauser、M. Bloesch、C. Gehring、M. Hutter 和 R. Siegwart。带不确定性估计的以机器人为中心的高程建图。见《移动服务机器人》，2014年。[82] Y. Pan、X. Xu、Y. Wang、X. Ding 和 R. Xiong。GPU加速的实时可通过性建图。见2019年IEEE国际机器人与仿生学会议（ROBIO），2019年。[83] B. Yang、L. Wellhausen、T. Miki、M. Liu 和 M. Hutter。利用学习到的运动代价进行实时最优导航规划。见2021年IEEE国际机器人与自动化会议（ICRA），2021年。[84] R. O. Chavez-Garcia、J. Guzzi、L. M. Gambardella 和 A. Giusti。从仿真中学习地面可通过性。IEEE机器人与自动化快报，2018年。[85] J. Guzzi、R. O. Chavez-Garcia、M. Nava、L. M. Gambardella 和 A. Giusti。基于局部运动估计的路径规划。IEEE机器人与自动化快报，2020年。[86] S. Yang、Z. Zhang、Z. Fu 和 Z. Manchester。Cerberus：面向敏捷运动的低漂移视觉-惯性-腿部里程计。ICRA，2023年。[87] M. Bloesch、S. Omari、M. Hutter 和 R. Siegwart。基于直接EKF方法的鲁棒视觉惯性里程计。见2015年IEEE/RSJ智能机器人与系统国际会议（IROS），第298–304页。IEEE，2015年。[88] D. Wisth、M. Camurri 和 M. Fallon。Vilens：用于全地形腿式机器人的视觉、惯性、激光雷达和腿部里程计。IEEE机器人学汇刊，2022年。

[89] D. Wisth、M. Camurri、S. Das和M. Fallon. 面向紧耦合激光雷达-视觉-惯性里程计的统一多模态地标跟踪. IEEE机器人与自动化快报, 6(2): 1004–1011, 2021.[90] R. Buchanan、M. Camurri、F. Dellaert和M. Fallon. 用于动态腿足机器人状态估计的惯性里程计学习. 载于机器人学习会议, 第1575–1584页. PMLR, 2022.[91] S. Yang、H. Kumar、Z. Gu、X. Zhang、M. Travers和H. Choset. 基于以接触为中心的腿部里程计的腿足机器人状态估计. arXiv预印本 arXiv:1911.05176, 2019.[92] D. Wisth、M. Camurri和M. Fallon. 基于因子图优化的鲁棒腿足机器人状态估计. IEEE机器人与自动化快报, 2019.[93] S. Omari、M. Bloesch、P. Gohl和R. Siegwart. 面向移动机器人的稠密视觉-惯性导航系统. 载于2015年IEEE国际机器人与自动化大会（ICRA）, 第2634–2640页. IEEE, 2015.[94] C. Forster、M. Pizzoli和D. Scaramuzza. Svo：快速半直接单目视觉里程计. 载于2014年IEEE国际机器人与自动化大会（ICRA）, 2014.[95] D. Scaramuzza和F. Fraundorfer. 视觉里程计 [教程]. IEEE机器人与自动化杂志, 2011.[96] M. DeDonato、V. Dimitrov、R. Du、R. Giovacchini、K. Knoedler、X. Long、F. Polido、M. A. Gennert、T. Padır、S. Feng等. 用于灾难响应的仿人机器人在环控制：DARPA机器人挑战赛试验报告. 现场机器人学杂志, 2015.[97] F. Jenelten、T. Miki、A. E. Vijayan、M. Bjelonic和M. Hutter. 粗糙地形中的感知运动：在线落脚点优化. IEEE机器人与自动化快报, 2020.[98] D. Kim、D. Carballo、J. Di Carlo、B. Katz、G. Bledt、B. Lim和S. Kim. 基于视觉的小型四足机器人非结构化地形动态探索. 载于2020年IEEE国际机器人与自动化大会（ICRA）, 2020.[99] M. Wermelinger、P. Fankhauser、R. Diethelm、P. Kr¨usi、R. Siegwart和M. Hutter. 腿足机器人在挑战性地形中的导航规划. 载于2016年IEEE/RSJ智能机器人与系统国际会议（IROS）, 2016.[100] A. Chilian和H. Hirschm¨uller. 基于立体相机的粗糙地形移动机器人导航. 载于2009年IEEE/RSJ智能机器人与系统国际会议, 2009.[101] C. Mastalli、I. Havoutis、A. W. Winkler、D. G. Caldwell和C. Semini. 四足运动的在线与机载规划及感知. 载于2015年IEEE实用机器人应用技术国际会议（TePRA）, 2015.[102] A. Agrawal、S. Chen、A. Rai和K. Sreenath. 基于运动库的离散地形视觉辅助动态四足运动. 载于2022年国际机器人与自动化大会（ICRA）, 2022.[103] J. Z. Kolter、M. P. Rodgers和A. Y. Ng. 一种粗糙地形四足运动的控制架构. 载于2008年IEEE国际机器人与自动化大会, 2008.[104] M. Kalakrishnan、J. Buchli、P. Pastor和S. Schaal. 使用地形模板学习粗糙地形上的运动. 载于2009年IEEE/RSJ智能机器人与系统国际会议, 2009.[105] L. Wellhausen和M. Hutter. 基于可达性规划和模板学习的腿足机器人粗糙地形导航. 载于2021年IEEE/RSJ智能机器人与系统国际会议（IROS）, 2021.

[106] C. Mastalli、M. Focchi、I. Havoutis、A. Radulescu、S. Calinon、J. Buchli、D. G. Caldwell和C. Semini. 基于低维模型的粗糙地形运动轨迹与落脚点优化. 载于2017年IEEE国际机器人与自动化大会（ICRA），2017.[107] O. A. V. Magana、V. Barasuol、M. Camurri、L. Franceschi、M. Focchi、M. Pontil、D. G. Caldwell和C. Semini. 基于卷积神经网络（CNN）的动态运动快速连续落脚点自适应. IEEE机器人与自动化快报，2019.[108] F. L. G. Bermudez、R. C. Julian、D. W. Haldane、P. Abbeel和R. S. Fearing. 腿足机器人在粗糙地形上的性能分析与地形分类. 载于2012年IEEE/RSJ智能机器人与系统国际会议，第513–519页. IEEE，2012.[109] V. Tsounis、M. Alge、J. Lee、F. Farshidian和M. Hutter. Deepgait：基于深度强化学习的四足步态规划与控制. IEEE机器人与自动化快报，2020.[110] X. B. Peng、G. Berseth、K. Yin和M. Van De Panne. Deeploco：基于分层深度强化学习的动态运动技能. ACM图形学汇刊（TOG），2017.[111] N. Rudin、D. Hoeller、P. Reist和M. Hutter. 使用大规模并行深度强化学习在数分钟内学会行走. 载于机器人学习会议，2022.[112] D. Jain、A. Iscen和K. Caluwaerts. 从像素到腿部：四足运动的分层学习. arXiv预印本 arXiv:2011.11722，2020.[113] A. Escontrela、G. Yu、P. Xu、A. Iscen和J. Tan. 视觉运动策略的零样本地形泛化. arXiv预印本 arXiv:2011.05513，2020.[114] J. Chung、C. Gulcehre、K. Cho和Y. Bengio. 门控循环神经网络在序列建模上的实证评估. arXiv预印本 arXiv:1412.3555，2014.[115] R. Tedrake. 轨迹优化. 欠驱动机器人学. URL http://underactuated.mit.edu/trajopt.html.[116] W. Zhou和D. Held. 通过涌现的外在灵巧性学习抓取不可抓取物体. 载于机器人学习会议，2022.[117] I. Mordatch、Z. Popovi´c和E. Todorov. 面向手部操作的接触不变优化. 载于ACM SIGGRAPH/欧洲图形学计算机动画研讨会论文集，2012.[118] J. Schulman、F. Wolski、P. Dhariwal、A. Radford和O. Klimov. 近端策略优化算法. arXiv预印本 arXiv:1707.06347，2017.[119] V. Makoviychuk、L. Wawrzyniak、Y. Guo、M. Lu、K. Storey、M. Macklin、D. Hoeller、N. Rudin、A. Allshire、A. Handa等. Isaac Gym：用于机器人学习的高性能GPU物理仿真. arXiv预印本 arXiv:2108.10470，2021.[120] Y. Burda、H. Edwards、A. Storkey和O. Klimov. 通过随机网络蒸馏进行探索. arXiv预印本 arXiv:1810.12894，2018.

A Experiment Videos

We perform thorough real-world analysis of our system. Indoor and outdoor experiment videos can be found at https://robot-parkour.github.io.

B Details of Training in Simulation

Specialized Skills. A specialize skill policy consists of a GRU followed by a MLP that outputs the target joint positions. We concatenate all the observations including proprioception, last action, recurrent latent state of the GRU, privileged visual information and privileged physics information as a flattened vector. It is passed to a one-layer GRU of 256 hidden sizes, followed by an MLP of hidden dimensions of [512, 256, 128]. We use ELU as the activation. The final layer outputs a 12-dimensional vector and be fed to tanh activation function. The action ranges from -1 to 1, which is scaled by a constant action scale: 0.4 for hip joints, and 0.6 for thigh and knee joints.

Rewards, Environments and PPO. We follow the insights from [10, 8, 35] that use fractal noises to generate terrains, which enforces the foot contact clearance. We use the reward terms for each specialized policies as listed in Table 3 to 7 in the supplementary. We use these parameters to train all five specialized policies, in either RL pre-training with soft dynamics constraint or fine-tuning the with hard dynamics constraints. The key parameters that related to the difficulties of the tasks are shown in the Table 1 of the main paper. Other parameters of the obstacles are set to constants: the obstacles for climbing is 0.8m wide and 0.8m long along the +x direction. The obstacles for the leaping task are gaps of 0.8m wide and 0.8m depth. For crawling, the obstacle is 0.8m wide and 0.3m in the +x direction. For tilting, the length along the +x direction is 0.6m. We use a set of fixed velocity commands v_x^{target} for each specialized skill during training. We list them in Table 8 of the supplementary. We sample environment randomizations on the robot mass, center of mass of the robot base, motor strength, terrain friction, depth perception latency, camera position, field of view and proprioception delay for each robot during training. The detailed environment randomization parameters are listed in Table 9. The detailed parameters of the PPO algorithm are listed in Table 10 of the supplementary.

Table 3: Reward Scales for Climbing

Purposes	Hyperparameter Variables	Values
x velocity	α_1	1.
y velocity	α_2	1.
angular velocity	α_3	0.1
energy	α_4	$2e-6$
penetration depth	α_5	$1e-2$
penetration volume	α_6	$1e-2$

Table 4: Reward Scales for Leaping

Purposes	Hyperparameter Variables	Values
x velocity	α_1	1.
y velocity	α_2	1.
angular velocity	α_3	0.05
energy	α_4	$2e-6$
penetration depth	α_5	$4e-3$
penetration volume	α_6	$4e-3$

Table 5: Reward Scales for Crawling

Purposes	Hyperparameter Variables	Values
x velocity	α_1	$1.$
y velocity	α_2	$1.$
angular velocity	α_3	0.05
energy	α_4	$2e-5$
penetration depth	α_5	$6e-2$
penetration volume	α_6	$6e-2$

Table 6: Reward Scales for Tilting

Purposes	Hyperparameter Variables	Values
x velocity	α_1	$1.$
y velocity	α_2	$1.$
angular velocity	α_3	0.05
energy	α_4	$1e-5$
penetration depth	α_5	$3e-3$
penetration volume	α_6	$3e-3$

Table 7: Reward Scales for Running

Purposes	Hyperparameter Variables	Values
x velocity	α_1	$1.$
y velocity	α_2	$1.$
angular velocity	α_3	0.05
energy	α_4	$1e-5$
penetration depth	α_5	0.
penetration volume	α_6	0.

Table 8: Velocity Commands for each Specialized Policy

Skills	v_x^{target} (m/s)
Running	0.8
Climbing	1.2
Leaping	1.5
Crawling	0.8
Tilting	0.5

Table 9: Environment Randomizations ($x \pm y$: Gaussian distribution; $[x, y]$: uniform distributions)

Parameters	Distributions
Added Mass	[1.0, 3.0] (kg)
Center of Mass (x)	[-0.05, 0.15] (m)
Center of Mass (y)	[-0.1, 0.1] (m)
Center of Mass (z)	[-0.05, 0.05] (m)
Friction Coefficient	[0.5, 1.0]
Motor Strength	[0.9, 1.1]
Forward Depth Latency	[0.2, 0.26] (s)
Camera Position (x)	0.27 ± 0.01 (m)
Camera Position (y)	0.0075 ± 0.0025 (m)
Camera Position (z)	0.033 ± 0.0005 (m)
Camera Pitch	$[0.0, 5.0]$ (deg)
Field of View	$[85, 88]$ (deg)
Proprioception Latency	[0.0375, 0.0475] (s)

Table 10: PPO Hyperparameters

PPO clip range	0.2
GAE λ	0.95
Learning rate	1e-4
Reward discount factor	0.99
Minimum policy std	0.2
Number of environments	4096
Number of environment steps per training batch	24
Learning epochs per training batch	5
Number of mini-batches per training batch	4

Parkour Policy. The parkour policy consists of a CNN encoder, a GRU and a MLP. The visual embedding from the CNN encoder is concatenated together with the rest of the observation (proprioception, last action and recurrent latent state of the GRU) and fed to the GRU whose output is then processed the MLP module. The detailed parameters of the network structure are listed in Table 11 of the supplementary. An illustration of the parkour training environment in simulation is shown in Figure 8.

Table 11: Parkour Policy structure

CNN channels	[16, 32, 32]
CNN kernel sizes	[5, 4, 3]
CNN pooling layer	MaxPool
CNN stride	[2, 2, 1]
CNN embedding dims	128
RNN type	GRU
RNN layers	1
RNN hidden dims	256
MLP hidden sizes	512, 256, 128
MLP activation	ELU

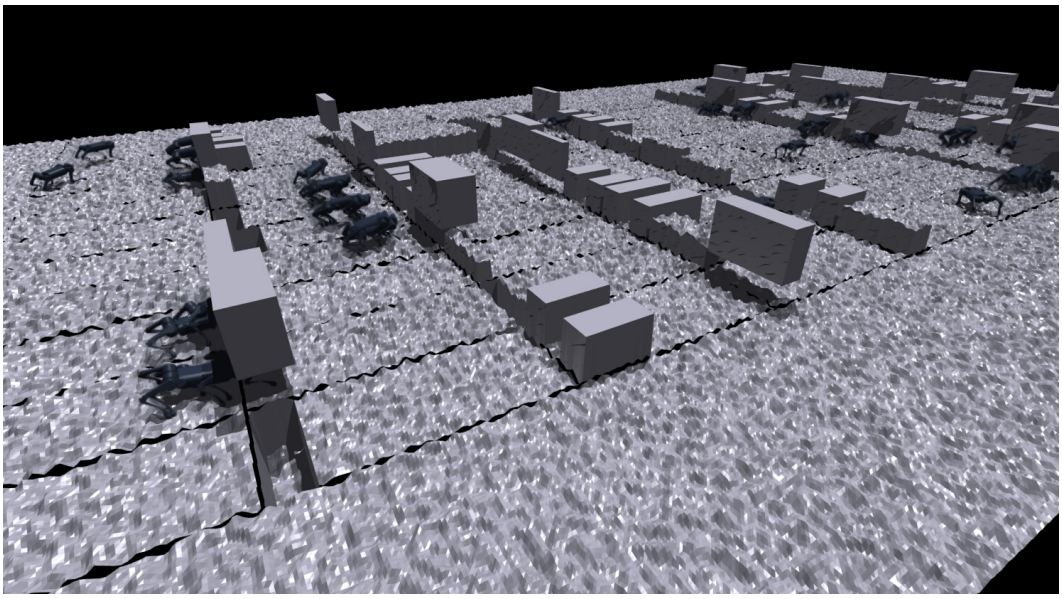

Figure 8: Parkour training environment in simulation during distillation.

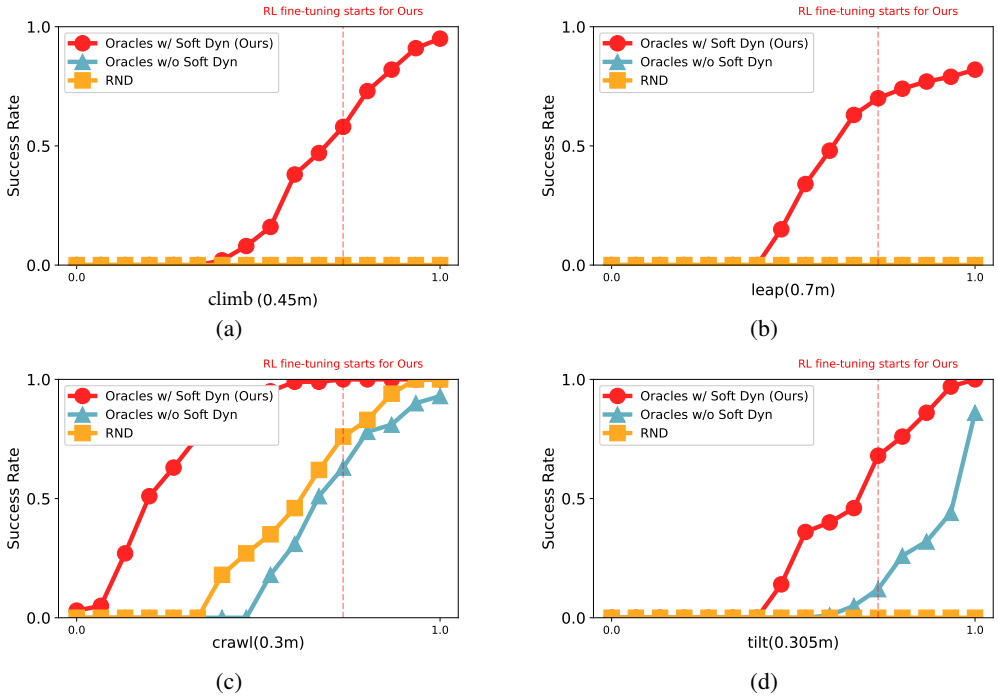

Figure 9: Comparison of our method with Oracles w/o Soft Dyn and RND. For our method, the RL finetuning stage started at the late stages of the training.

We use binary cross-entropy loss for the parkour policy during distillation. The output of both specialized skills and the parkour policy ranges from -1 to 1.

$$D(a^{\text{parkour}}, a^{\text{specialized}}) = \left(\frac{1 + a^{\text{specialized}}}{2} \log \frac{1 + a^{\text{parkour}}}{2} + \frac{1 - a^{\text{specialized}}}{2} \log \frac{1 - a^{\text{parkour}}}{2} \right) \times 2,$$

where $a^{\text{specialized}}$ is the action from the corresponding specialized skill, a^{parkour} is the action from the parkour policy.

C Details of Simulation Setup

We use IsaacGym Preview 4 for simulation. We generate a static large terrain map before each training, during the training of specialized policies. The terrain consists of 800 tracks with a 20 by 40 grid. We set the difficulty of each track in a linear curriculum manner. The tracks in the same row have the same difficulty but differ in non-essential configurations. The tracks in each column are connected end to end so that whenever the robot finished the current track, it keeps moving forward (+x direction) to the more difficult track. We train each specialized policy in soft dynamics using one 1 Nvidia 3090 computer for 12 hours and tune it in hard dynamics for 6 hours. For distillation, we use 4 computers, each of which is equipped with 1 Nvidia 3090 GPU, that share the same NFS file system. We use 3 computers for loading the current training model and collecting the parkour policy's trajectory as well as the specialized policy supervision. We use the other one computer to load the latest trajectories and train the parkour policy.

D Details of Robot Setup

We use the Unitree A1 equipped for our real-world experiments which is equipped with an onboard Nvidia Jetson NX. The robot has 12 joints. Each joint is equipped with a motor of 33.5Nm instant maximum torque. It also has a built-in Intel RealSense D435 camera in front of the robot using inferred and stereo to provide depth images. We use ROS1 on Ubuntu 18.04 which runs on the onboard Jetson NX. We use a ROS package based on Unitree SDK to send and receive the robot states as well as the policy command at 100Hz. The ROS package is also equipped with a roll/pitch limit, estimated torque limit, and emergency stop mechanism using the remote control as the means of protection for the robot. To run the policy, we use two Python scripts: a CNN script to run the

visual encoder asynchronously and a main script to run the rest of the networks. We use the Python wrapper of librealsense to capture depth images at the resolution of 240 X 424. We apply the holing filters, spatial filters, and temporal filters from the librealsense utilities. We crop the 60 pixels on the left and 46 pixels on the right before down-sampling the depth image to 48 X 64 resolution. The visual embedding is sent to the main script using ROS message at 10Hz. We fix the policy inference frequency to 50Hz. In each loop, we update the robot proprioception and the visual embedding using ROS and compute the policy output actions. Then we clip the action by a range computed using the current joint position and velocity at a maximum torque of 25Nm, and send the position control command to the ROS package, with $K_p = 50.0, K_d = 1.0$.

E Detailed Comparison Studies on RL Pre-Training with Soft Dynamics Constraints

We compare our method with RND and the Oracles w/o Soft Dyn. Our method trained with soft dynamics constraints is the only method that can complete climbing and leaping skills. As shown in Figure 9 of the supplementary, except for crawling, RND fails to learn successful maneuvers to achieve climbing, leaping, and tilting. Although the Oracles w/o Soft Dyn learned to achieve crawl and tilt skills, but fail to learn to climb and leap, which are the most difficult skills among all the skills in this paper.