arXiv:2508.12252v2 [cs.RO] 26 Aug 2025

机器人训练机器人：为拟人化机器人自动真实世界策略适应与学习

Kaizhe Hu **Haochen Shi*** **Yao He** **Weizhuo Wang** **C.Karen Liu**† **Shuran Song**†*
*同等贡献 †同等指导 斯坦福大学
robot-trains-robot.github.io

摘要：基于模拟的强化学习（RL）已显著提升了人形机器人运动任务，但从头开始直接在现实世界中进行RL或从预训练策略中适应的情况仍然罕见，这限制了人形机器人的全部潜力。现实世界学习虽然对于克服模拟到现实的差距至关重要，但面临着与安全、奖励设计和学习效率相关的重大挑战。为解决这些限制，我们提出了机器人-训练-机器人（RTR）这一新颖框架，其中机械臂教师主动支持和指导人形机器人学生。RTR系统提供保护、学习计划、奖励、扰动、故障检测和自动重置功能。它能够以极少量的人工干预实现高效的人形机器人长期现实世界训练。此外，我们提出了一种新的RL流程，通过优化现实世界中的单个动态编码潜在变量，促进并稳定模拟到现实的迁移。我们通过两个具有挑战性的现实世界人形机器人任务验证了我们的方法：为精确速度跟踪微调行走策略，以及从头开始学习人形机器人摆起任务，展示了RTR式系统实现的现实世界人形机器人学习的潜力。

关键词：人形机器人，仿真到现实自适应，现实世界强化学习

1 引言

近年来，在利用大规模并行仿真环境训练强化学习（RL）策略方面取得了显著进展，在人形机器人运动任务中 [1,2, 3, 4, 5]取得了显著成果。这些方法展示了在物理人形机器人上以零样本方式或通过现实世界自适应进行部署的能力。

然而，直接在现实世界中学习仍然可以说是追求最佳性能的最有效方式，因为它绕过了不可避免的模拟到现实的差距 [6]。这对于人形机器人等复杂系统尤其关键，因为模拟与现实世界动力学之间的差异会显著阻碍策略能力。尽管有这些优势，人形机器人在现实世界中的学习，无论是从零开始还是微调，都由于几个关键因素而保持高度挑战性：

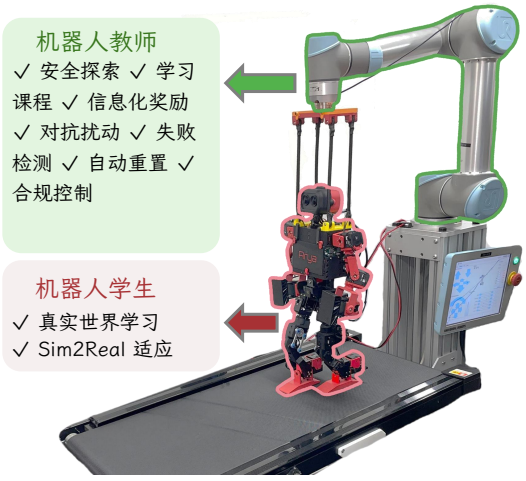


图1：机器人训练机器人（RTR）。我们提出RTR用于自动现实世界策略自适应和学习，以机械臂为教师，人形机器人为学生。

第9届机器人学习会议（CoRL 2025），首尔，韩国。

• 安全性：现实世界的强化学习在探索过程中可能产生意外和危险的行为，轻易打破人形机器人的脆弱平衡。当前方法通常在现实世界部署期间将人形机器人悬挂在固定桁架上，不可避免地限制了数据收集的范围。这种被动的保护机制也会影响学习效率，因为桁架会频繁拖拽机器人，导致它在策略稳定之前就摔倒。

• 奖励设计：模拟环境中许多有用的奖励信号，如全局速度或外部力，很难或无法直接在物理机器人本身上测量，这给现实世界的奖励设计带来了复杂性。

• 学习效率：现实世界训练需要频繁重置，这会带来高昂的人力成本。学习算法的样本效率低下进一步加剧了这些问题，因为现实世界的数据收集本质上既昂贵又受限。

这些考虑突出了对一种全面且实用的系统的需求，该系统专门为现实世界的人形学习而设计。为了应对这些挑战，我们提出了一种新颖的现实世界策略适应和学习范式：机器人训练机器人（RTR），其中一位教师机器人（一个带力反馈的机械臂）训练另一位学生机器人（一个拟人机器人）。具体来说：

• 为了解决安全问题，RTR使用一个带力-力矩传感的机械臂，通过顺应控制主动支持和向人形机器人提供交互式力反馈，从而允许在多种行为中进行广泛且安全的探索。

• 为了收集关键的奖励信息，RTR利用教师机器人的实时测量来推导出在现实世界中难以获得的代理奖励信号。

• 为提高学习效率，RTR采用自动课程来提供程序指导，动态调整训练难度，并有意地扰动机器人以增强鲁棒性。RTR系统还支持故障检测、自动重置以及异步的数据收集和策略更新管道，显著减少了人工干预，并实现了高通量数据收集。

此外，为了进一步提高学习效率，我们提出了一种新颖的模拟到现实微调算法。我们的方法包括一个三阶段流程：首先，我们通过领域随机化在模拟中训练一个感知动力学的策略，通过潜在编码器和FiLM [7] 层将环境物理信息嵌入策略中。接下来，我们在各种模拟环境中优化一个通用潜在向量，为后续的现实世界训练提供稳健的初始化。最后，利用RTR硬件，我们有效地在现实世界中细化动力学生成潜在，使用PPO [8], 显著提高了策略在现实世界中的性能和鲁棒性。

我们通过两个具有挑战性的真实世界人形机器人任务来评估我们的系统和方法：微调用于精确速度跟踪的行走策略，以及从头学习人形机器人起摆行为。给定期望的速度指令，RTR 仅通过 20 分钟的真实世界训练即可将零样本行走速度有效提高一倍。在起摆任务中，人形机器人成功地从头学习在 15 分钟的真实世界交互内实现周期性起摆运动。虽然我们使用开源的小型人形机器人 ToddlerBot [9], 实现了 RTR 系统，但所提出的范式可以很容易地推广到全尺寸人形机器人。当代工业机器人手臂能够抬起和与人交互的最大有效载荷高达 600 kg [10], ，这表明 RTR 具有广泛的适用性，可以应用于各种人形机器人平台。

总而言之，我们的贡献包括：(1) 一个全面的现实世界学习系统，提供关键的保护、指导、自动化和针对现实世界人形学习的定制化信息反馈。(2) 一种利用动态感知潜在优化的高效强化学习范式，用于快速稳定的现实世界策略适应。(3) 通过两个具有挑战性的任务验证了我们的方法，突出了RTR的效率和其在支持及泛化跨多种现实世界学习场景方面的能力。

2 相关工作

为解决仿真到现实的差距 [6] 并提高现实世界的策略性能，主要有三种主流方法：零样本仿真到现实迁移、在仿真中进行策略预训练然后进行现实世界适应，以及从随机初始化开始直接在现实世界进行强化学习。

零样本仿真到现实迁移。直接将仿真预训练策略部署到现实世界容易因仿真到现实的差距而失败。在仿真中进行大量领域随机化预训练已成为在操作 [11, 6, 12] 和移动 [13, 14, 15, 16, 17]任务中都非常有效的策略。这种方法甚至在具有丰富接触交互 [18, 19, 20, 21, 22] 的灵巧操作和具有内在不稳定性动力学的复杂人形移动等具有挑战性的环境中都取得了显著成功。然而，不恰当的领域随机化可能会产生策略，这些策略要么无法有效地适应现实条件，要么变得过于保守，从而限制性能。

现实世界适应。一种流行的弥合仿真到现实差距的方法是利用现实世界数据。这些方法通常依赖于一个稳健的预训练策略来安全地生成策略数据，从而在特定任务分布内进行有针对性的探索。一些适应方法使用现实世界数据来调整仿真参数分布，使仿真策略行为更紧密地与现实世界经验 [26, 27, 28]对齐。其他方法采用在线适应技术来微调潜在表示 [29, 30, 31, 32], 残差策略 [33, 1], 或直接优化原始策略 [34, 35, 36]。此外，一些研究结合在线人类纠正来改进策略 [37, 38]。值得注意的是，由于人形的内在不稳定性，在现实世界适应期间保持安全具有挑战性。因此，较少的研究关注人形 [1, 32],，这突显了需要专门的系统来支持安全有效的人形适应。我们提出的动力学潜在调整管道与基于上下文的元RL方法 [39, 40], 最为相似，其中从过去的观察或物理参数中提取一个潜在向量，并在元预训练期间用于将策略调整为适应不同的任务或环境。该潜在向量可以在现实世界中优化，以实现快速策略适应。虽然这些方法在四足移动任务 [41, 42], 中已显示出成功，但它们隐式依赖于四足的内在稳定性，以安全地启动现实世界交互。对于人形，任何初始性能差距都可能导致摔倒或硬件损坏。尽管早期尝试已将此类方法部署到人形 [43], , 但它们依赖于简单的平台和脚本策略进行初始数据收集，这对于更复杂的人形系统是不切实际的。与之前的工作相比，RTR结合了精心设计的硬件设置和仿真优化的初始潜在，使得这一类算法能够在人形机器人上实现现实世界应用。

现实世界强化学习。对于难以模拟或存在较大模拟与现实差距的任务，直接在现实世界中训练通常更可取。一些研究已成功采用这种方法，涵盖各种场景，包括桌面操作 [44], 精巧操作 [45], 移动操作 [46], 以及四足运动 [47, 48, 49, 50]。然而，由于存在一些尚未解决的挑战，鲜有研究探索使用拟人机器人进行直接现实世界强化学习：(1) 在训练早期阶段保持拟人机器人的稳定性并防止跌倒，(2) 确保安全高效的复位机制，以及 (3) 提供充分的反馈和具有信息量的奖励信号。其中一项值得注意的研究由 Bloesch 等人 [51] 采用了一个更简单的拟人机器人平台 [52]，该平台具有 20 个自由度，通过端到端强化学习进行移动。我们提出 RTR 来解决这些挑战，并使更复杂的拟人机器人平台上的现实世界强化学习成为可能。

3 方法

3.1 教师学生硬件系统

教师设置。我们使用6自由度UR5机械臂支持人形机器人。一个ATI mini45力-力矩（F/T）传感器安装在机械臂的末端执行器上，用于测量交互力。四根弹性绳索将机械臂的末端执行器连接到人形机器人的肩膀。绳索的弹性至关重要，因为它能够实现更平滑的力传递，并避免在刚性连接或非弹性绳索中常见的突然力变化。

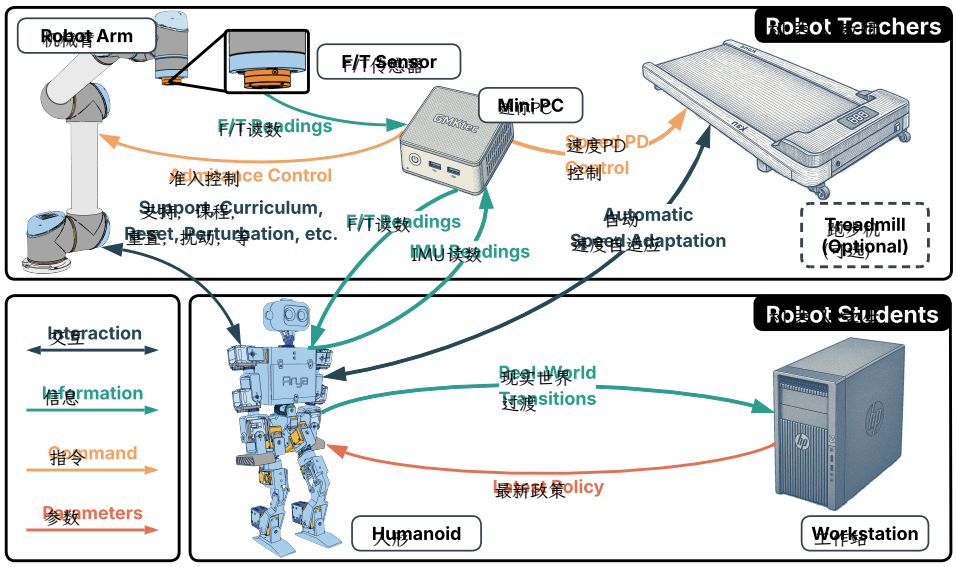


图2：系统设置。我们展示了系统架构和组件交互。系统由两组组成：机器人教师和机器人学生。教师包括一个带有F/T传感器的机械臂、一台迷你PC，以及一个可选的跑步机用于运动任务；学生包括一个拟人机器人和一个用于策略训练的工作站。四种类型的线条分别代表物理交互、数据传输、控制命令和神经网络参数。

对于行走实验，我们额外提供了一台可编程跑步机，以确保机器人保持在机械臂的范围内。这台跑步机配备了位置编码器和微控制器，以提供闭环控制移动速度。如图2所示，一台迷你PC通过以太网电缆连接到机械臂、F/T传感器和跑步机，同时通过WiFi与学生机器人通信。这台迷你PC具有以下功能：(1)向机械臂和跑步机发送控制信号，以确保它们能够正确辅助人形机器人的学习，以及(2)从F/T传感器和跑步机收集数据，以调整课程内容、重置计时并收集机器人的奖励信息。

学生设置。我们使用开源拟人机器人ToddlerBot [9]，因为它体积紧凑（0.56米，3.4公斤）、灵活性高（30个自由度）、易于获取（成本低于6,000美元）且鲁棒性强。UR5机械臂，具有5公斤的负载能力，能够提供足够的支撑。由于安全性是现实世界学习中的主要关注点，在像ToddlerBot这样轻量级且多功能的平台上验证我们的算法，可以实现无人值守操作，而不会损坏机器人本身或周围环境。此外，对于拟人机器人而言，硬件可靠性同样重要——ToddlerBot的电机具有足够的抗过热能力，并能够连续运行超过>1小时，这使得机器人非常适合我们的现实世界学习任务。

3.2 真实场景适配

真实场景适配，即在实际场景中微调模拟预训练策略，对于提升高要求运动任务的表现至关重要。在本节中，我们应用真实场景适配流程来微调用于精确速度追踪的行走策略，而我们的设置适用于适配跑步和全身轨迹跟踪等多种运动任务。

在教师方面，我们介绍一种自动化的课程，该课程能动态调整支持力，并实现快速水平柔性臂跟随。在学生方面，我们提出一种基于领域随机化和动力学潜在优化的通用仿真到现实自适应算法。我们首先介绍我们的三阶段学生学习算法，如图3所示，然后描述教师在实际世界中的自适应策略。

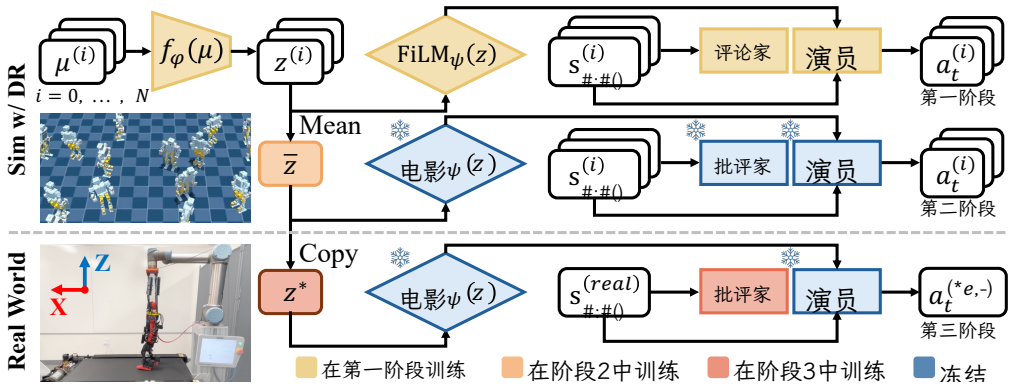


图3：仿真到现实的微调算法。我们展示了我们的仿真到现实微调过程。首先，我们通过领域随机化（DR）在仿真中训练一个感知动力学的策略，将环境物理编码到一个潜在向量中。接下来，我们在各种仿真环境中优化一个通用潜在向量，以初始化现实世界训练。最后，我们细化潜在向量并在现实世界中训练一个新的评价器。橙色表示三个阶段中可训练的组件；蓝色表示冻结的组件。

动力学条件策略训练。在第一阶段，我们训练一个动力学感知策略 $\pi(s, z)$，该策略基于当前观测 s 和 $N = 1000$ 领域随机化仿真环境中的动力学潜在 z（更多细节见附录A）。具体来说，对于第 i 个环境，我们使用多层感知机（MLP）编码器 f_ϕ 将环境特定的物理参数 $\mu^{(i)}$ 编码为潜在表示 $z^{(i)}$：$z^{(i)} = f_\phi(\mu^{(i)})$。该动力学潜在随后通过特征线性调制（FiLM）层 [7] 融入标准PPO行动网络。具体而言，设 $h_j^{(i)}$ 表示行动网络中第 j 层激活函数后的隐藏潜在，我们使用FiLM对其进行调制，如下：

$$\gamma_j^{(i)}, \beta_j^{(i)} = \text{FiLM}_j(z^{(i)}), \quad h_j^{(i)} \leftarrow \gamma_j^{(i)} \odot h_j^{(i)} + \beta_j^{(i)}, \tag{1}$$

其中 $\gamma_j^{(i)}$ 和 $\beta_j^{(i)}$ 是由FiLM层从潜在向量 $z^{(i)}$生成的缩放和平移参数，$\odot$表示逐元素乘法。编码器网络 f_ϕ 和FiLM调制策略网络 $\pi(s, z)$ 在随机化的领域中联合使用PPO进行训练，参数为 $\mu^{(i)}$，允许策略有效利用潜在动力学信息并适应各种仿真环境。经验上，我们发现FiLM层的学率至关重要：太小会导致策略忽略动力学潜在，太大则会导致不稳定性。这种效应的消融研究在附录B中提供。通用潜在优化。当在现实世界中部署感知动力学策略时，会出现一个实际挑战：现实世界的初始潜在表示 z 未知，因为环境特定参数 μ不可用。因此，我们提出了第二阶段，从 $\bar{z}$（所有训练环境潜在向量的平均值）开始优化一个通用潜在$\tilde{z}$。形式上，我们冻结策略网络和FiLM层参数，使用PPO优化 $\tilde{z}$，旨在在所有领域随机化的仿真环境中实现鲁棒性能：

$$\tilde{z} = \arg\max_z \sum_i \mathbb{E}_{\tau \sim \pi(\cdot|z),\, \mathcal{T}_i}[J(\tau)] \tag{2}$$

$\mathcal{T}_i$ 表示第 i个环境的转换分布，J 表示PPO算法的优化目标，即策略 π下的预期累积奖励，并且期望值是在策略和环境动态共同诱导的联合分布上计算的。得到的潜在 $\tilde{z}$ 为实际部署提供了稳健的初始条件。

实际场景微调。在此阶段，我们冻结行为网络和FiLM层参数，使用 $\tilde{z}$ 作为初始解，在真实场景中对潜在变量进行微调。同时，由于真实场景中缺乏特权观测数据，我们从零开始训练评价网络，导致其观察空间与模拟场景不同。

对于行走任务，奖励机制设计为鼓励追踪目标速度，其定义如下：

$$r = \exp\left(-\sigma \cdot (v - v^{\text{target}})^2\right), \tag{3}$$

v 和 v^{target} 分别是当前和目标机器人速度，而 $\sigma = 100$ 是一个奖励塑形的超参数。由于人形机器人是在跑步机上行走，其躯干在全局坐标系中相对静止——状态估计或运动捕捉得到的速度接近于零。因此，我们用跑步机的速度来近似 v 。

现实世界的教师。机器人教师包括带F/T传感器的机械臂、迷你PC和跑步机。它们共同提供引导、调度、奖励、失败检测和自动重置功能。(1)引导：利用F/T传感器的反馈，我们采用阻抗控制 [53, 54]对机械臂进行控制。机械臂在XY轴上保持顺应性，以适应人形机器人产生的相对运动（图3）。这种配置允许人形机器人在XY方向自由移动，同时保持直立姿势。(2)调度：为了逐渐减少辅助，我们实施了一种调度策略，机械臂的高度在 5×10^4 环境步长中线性减少0.02米，在训练结束时将支撑力降至接近零。(3)奖励：我们还基于F/T传感器沿X轴的力和人形机器人躯干的俯仰角，在跑步机的速度上实施了PD反馈控制回路。这个反馈回路帮助机器人保持直立行走姿势，并确保跑步机速度反映人形机器人的行走速度。我们进一步使用这个跟踪速度来提供等式(3)中的奖励信号。(4)失败检测和自动重置：此外，RTR如果人形机器人躯干的俯仰角超过阈值，或F/T传感器沿X轴或Y轴读取到较大的力，会自动检测到失败，提示系统进行步进，并让机械臂抬起人形机器人以重置训练。

3.3 从零开始学习现实世界

虽然仿真到现实的学习对于人形机器人行走有效，但在涉及难以仿真的物体（如可变形物体）的任务中则效果不佳。RTR也适用于此类情况下的直接现实世界训练。为了展示这种灵活性，我们引入了一个具有挑战性的现实世界强化学习任务——学习举升行为（图5），由于缆线动力学的复杂性，该任务难以仿真。

三阶段训练。受 Lei 等人 [35], 的启发，我们使用一个三阶段训练流程：(1) 使用 PPO 在现实世界中从头开始训练 Actor 和 Critic，并收集 50,000 步次优状态转移数据；(2) 使用离线强化学习在这些数据上预训练 Critic；(3) 在加载预训练的 Critic 的同时初始化一个新的 Actor，并继续联合训练这两个网络。奖励设计为最大化由力传感器在摆动过程中测量的主导周期性力的幅值。具体来说，我们对沿 x 轴最新的 1,000 次力读数应用快速傅里叶变换 (FFT)，以获得频域中的力频谱并检索主导频率，记为 ν_x。然后我们提取该频率处的力幅值 $\hat{A}_{\nu_x}$，并将奖励定义为：

$$r = \exp\left(-\alpha \cdot (\hat{A}_{\nu_x} - A^{\text{target}})^2\right), \tag{4}$$

$\alpha = 0.005$ 和 $A^{\text{target}} \approx mg\theta_0$ 在摆动的小角度近似下如何推导。 $m = 3.5$ kg是质量， $\theta_0 = 30^\circ$ 是预期的最大角位移。

现实中的教师。机器人教师通过放大摆动或阻尼摆动来引导人形机器人的摆起动作。这两种策略都与人形机器人当前主导力频率下的摆动角度 θ_t 相位对齐。(1) 引导：为放大摆动，即增加主导频率处的力幅，手臂被赋予位置目标$x_t = x_0 + A_{\text{arm}}\cos(\theta_t)$。(2) 扰动：为阻尼摆动，即减小力幅，手臂被赋予相位反转的位置目标 $x_t = x_0 - A_{\text{arm}}\cos(\theta_t)$，其中 $A_{\text{arm}} = 0.05$ m，且 x_0 表示手臂的初始 x-轴位移。(3) 计划：我们将每个数据批次均匀分成多个桶，并随机选择一定数量的桶应用引导或扰动。手臂在其余桶中保持固定位置。最终的训练计划包括帮助、扰动和保持静止的混合阶段。

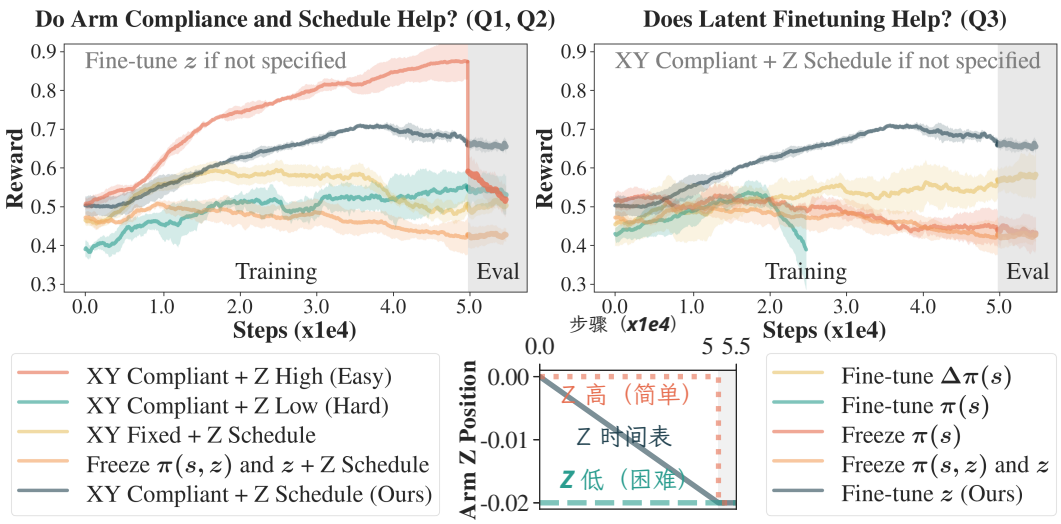


图 4：行走消融。此实验旨在评估手臂反馈控制和潜在向量微调的有效性。我们展示了训练和评估期间的线性速度跟踪奖励，手臂时间表显示在底部中心。所有变体均在相同条件下进行测试：手臂使用 XY 顺应策略，Z 固定在 Δ 位置，为 -0.02 米。我们使用三个随机种子进行每个实验，并在图中显示平均值和标准差。除非另有说明，否则假设 Finetune z、XY 顺应和 Z 时间表。

表1：我们在该表中评估了行走基线。人形机器人的任务是跟踪跑步机速度 (0.15 m/s)。为评估行走稳定性，人形机器人的IMU测量躯干俯仰和滚转（弧度），而F/T传感器测量末端执行器（EE）力 (N)。除非另有说明，否则假设Finetune z、XY compliant和Z计划。

方法	躯干滚动 ↓	躯干俯仰 ↓	力控 X ↓	力控 Y ↓	力控 Z ↓
冻结 $\pi(s)$	0.124 ± 0.012	0.102 ± 0.034	1.217 ± 0.134	1.235 ± 0.065	3.431 ± 0.606
微调 $\Delta\pi(s)$	0.102 ± 0.032	0.096 ± 0.031	1.007 ± 0.025	1.078 ± 0.136	2.316 ± 0.486
冻结 $\pi(s, z)$	0.110 ± 0.021	0.064 ± 0.014	1.672 ± 0.174	1.088 ± 0.186	3.654 ± 0.988
Z固定 （高）	0.151 ± 0.030	0.126 ± 0.011	1.064 ± 0.143	0.993 ± 0.279	2.402 ± 0.732
Z固定 （低）	0.199 ± 0.113	0.112 ± 0.053	1.254 ± 0.133	0.882 ± 0.104	3.237 ± 1.196
XY固定	0.170 ± 0.030	0.156 ± 0.027	1.175 ± 0.130	0.864 ± 0.100	2.299 ± 0.820
RTR (我们)	$\mathbf{0.093 \pm 0.020}$	$\mathbf{0.053 \pm 0.044}$	$\mathbf{0.943 \pm 0.202}$	$\mathbf{0.754 \pm 0.122}$	$\mathbf{0.954 \pm 0.445}$

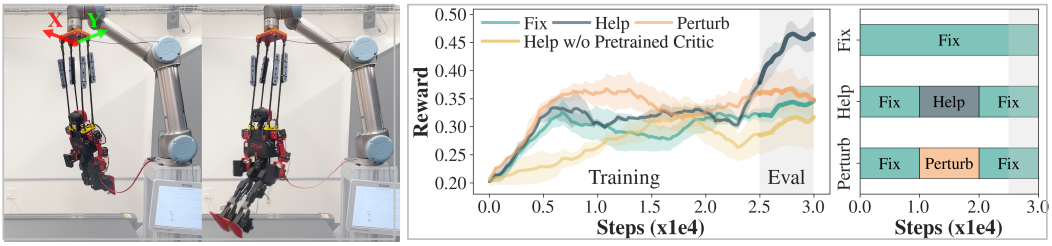
4 实验

4.1 基于仿真预训练的现实世界适应：行走

概述。我们考虑在跑步机上行走，同时精确追踪跑步机速度的任务，以展示RTR的现实世界适应能力。在训练和评估过程中，奖励定义为跑步机速度，通过IMU和力读数反馈控制跑步机速度。在测试过程中，通过固定跑步机速度0.15 m/s（表1）下的行走稳定性来衡量性能。我们进行消融研究，以回答三个关键问题：(Q1)手臂顺应性控制有帮助吗？(Q2)手臂调度有帮助吗？(Q3)在现实世界适应中，微调 z^*是否更数据高效？

手臂顺应性。如图4左侧所示，我们比较了RTR与基线XY固定+ Z调度，其中手臂保持静止，无法适应人形机器人在行走过程中的XY运动。我们观察到手臂经常拖拽人形机器人向后，并损害策略适应。在评估过程中，重新启用顺应性控制，以确保公平比较。

臂部调度。我们将我们的线性递减臂部高度调度与两种替代调度策略进行比较：XY兼容 + Z高（简单）和XY兼容 + Z低（困难）。不同的臂部调度策略显示在图4的中央下方。Z高（简单）训练



(a) 振起任务　　(b) 振起消融　　(c) 手臂调度

图5：振起消融。我们展示了振起设置和实验结果。(a) 人形机器人悬挂在机械臂上，用腿部积累动量并最大化绳索角度。(b) 我们比较了帮助型手臂调度和扰动型手臂调度与固定手臂基线，并评估了无预训练评价器的帮助型调度。每个实验使用三个随机种子运行，图像显示均值和标准差。(c) 我们展示了三种手臂调度，帮助和扰动发生在中间阶段，手臂在开始和结束时固定。

对于 Z 低（困难），训练和评估的臂部高度相同，因此策略理想情况下应该过拟合到臂部高度。然而，由于初始任务难度较高，策略在早期阶段经常失败，导致微调数据质量较差，并且与我们的方法相比，奖励改进速度较慢。

微调潜在空间。我们比较了RTR与两种微调策略：微调 $\pi(s)$和微调 $\Delta\pi(s)$（图4）。直接微调 $\pi(s)$初始进展良好，但很快崩溃。在微调 $\Delta\pi(s)$中，基线策略 $\pi(s)$被冻结，一个残差策略从$\pi(s)$初始化并训练，最后一层权重重置为零。我们发现RTR比两个基线具有更好的数据效率。所有方法使用相同的手臂策略，XY compliant +Z调度。为参考，我们还展示了在没有微调 $\pi(s)$或 $\pi(s,z)$的情况下，随着手臂降低任务难度增加，奖励逐渐减少。我们还在附录D中比较了RTR与RMA [30]。

4.2 从零开始的现实世界学习：摆起

概述。为了展示 RTR 在从零开始的现实世界学习中的有效性，我们考虑在现实世界中通过强化学习训练摆起行为。目标是将在 20 秒的时间窗口内达到最大摆起高度。为了简化任务，我们将动作空间约束为髋关节俯仰、膝关节俯仰和踝关节俯仰，并强制左右腿之间的对称性。我们进行消融实验来回答两个关键问题：(Q1) 在训练计划中，主动参与手臂是否有助于训练？(Q2) 批评器预训练是否有帮助？

分析。如图 5 所示，帮助手臂和扰动手臂都优于固定手臂，其中帮助手臂表现最佳。我们得出结论，帮助允许批评器在帮助间隔期间（1e4 – 2e4 步）学习良好状态的样子，从而使策略能够快速达到这些状态。使用离线数据预训练值函数也加速了早期学习——没有预训练批评器的模型表现出最慢的改进。

5 结论

我们提出了一种全面的现实世界学习系统RTR，它能够为拟人化学习提供保护、指导、调度、奖励、扰动、故障检测和自动重置功能。我们介绍了一种基于动态感知潜空间优化的高效强化学习范式，能够实现现实世界中的快速且稳定的策略适应。展望未来，我们计划将RTR扩展到更大的拟人化机器人，处理日益复杂的任务，并进一步提高数据效率，从而更有效地收集和利用现实世界数据，用于拟人化学习。

6 限制

尽管RTR能够在现实世界中自主执行训练课程，但课程本身仍然是任务特定的，需要手动设计和调整。未来的工作应探索更通用的现实世界课程生成方法。此外，我们的奖励设计受限于硬件和传感器的可用性——例如，RTR无法获取地面反作用力测量数据，这些数据在模拟中 *readily available* 但在我们的现实世界设置中不存在，而将力台安装在跑步机下方是一个潜在的解决方案。开发全面的现实世界感知方法代表了推进现实世界环境中持续机器人学习的有前景的方向。

RTR 的一项有前景的未来发展方向是扩展到全尺寸人形机器人。尽管当前设置由于载荷限制无法处理此类机器人，但 RTR 的原则——一个动态、力感知的教师-学生系统，在现实世界学习中提供关键的学习课程、安全保证和自动重置——通常适用。对于更大的人形机器人，机器人教师可以是工业机器人手臂或带力传感的桥式起重机，后者还将消除对跑步机的需求，因为起重机可以在广阔的水平区域内移动。

致谢

作者们向 Yifan Hou 表达由衷的感谢，感谢其在机器人手臂 Compliance 控制器方面提供的宝贵帮助和反馈。我们感谢陈思睿、徐培、雷坤、吴阿尔伯特、王若诚和曹壮在 humanoid 强化学习方面的意见。最后，我们感谢 TML 和 REALab 所有成员的有益讨论。

这项工作得到了 NSF 奖项 #2143601、#2037101、#2132519、#2153854、Sloan 奖学金以及斯坦福大学以人为本的人工智能研究所的部分支持。我们感谢谷歌提供的 UR5 机器人硬件。本文所述的观点和结论仅代表作者本人，不应被解释为必然代表赞助方的官方政策，无论是明示还是暗示。

参考文献

[1] T. He, J. Gao, W. Xiao, Y. Zhang, Z. Wang, J. Wang, Z. Luo, G. He, N. Sobanbab, C. Pan, Z. Yi, G. Qu, K. Kitani, J. Hodgins, L. J. Fan, Y. Zhu, C. Liu, 和 G. Shi. ASAP：对齐模拟与现实物理以学习灵巧的人形全身技能，2025年2月.[2] T. He, W. Xiao, T. Lin, Z. Luo, Z. Xu, Z. Jiang, J. Kautz, C. Liu, G. Shi, X. Wang, L. Fan, 和 Y. Zhu. HOVER：适用于人形机器人的通用神经全身控制器，2025年3月.[3] I. Radosavovic, T. Xiao, B. Zhang, T. Darrell, J. Malik, 和 K. Sreenath. 基于强化学习的人形机器人现实世界运动控制，Science Robotics，9(89):eadi9579，2024年4月。doi: 10.1126/scirobotics.adi9579 .[4] I. Radosavovic, S. Kamat, T. Darrell, 和 J. Malik. 在挑战性地形上学习人形机器人运动，2024年10月.[5] Z. Zhuang, S. Yao, 和 H. Zhao. 人形机器人跑酷学习。在第八届机器人学习年会上，2024年9月.[6] J. Tobin, R. Fong, A. Ray, J. Schneider, W. Zaremba, 和 P. Abbeel. 域随机化：将深度神经网络从模拟迁移到现实世界。在2017年IEEE/RSJ国际智能机器人与系统会议（IROS）上，第23-30页，2024年9月。doi: 10.1109/IROS.2017.8202133 .[7] E. Perez, F. Strub, H. de Vries, V. Dumoulin, 和 A. Courville. Film：使用通用条件层进行视觉推理，2017。URL https://arxiv.org/abs/1709.07871.[8] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, 和 O. Klimov. 近端策略优化算法，2017。URL https://arxiv.org/abs/1707.06347.[9] H. Shi, W. Wang, S. Song, 和 C. K. Liu. ToddlerBot：开源的、兼容机器学习的人形机器人平台，用于运动与操作，2025年2月.[10] Research Nester. 工业机械臂市场规模、份额、增长趋势、区域份额、竞争情报、预测报告2025-2037，2025年3月。URL https://www.researchnester.com/reports/industrial-robotic-arm-market/6763. 访问时间：2025-04-28.[11] X. B. Peng, M. Andrychowicz, W. Zaremba, 和 P. Abbeel. 基于动态随机化的机器人控制模拟到现实的迁移。在2018年IEEE国际机器人与自动化会议（ICRA）上，第3803-3810页，2018年5月。doi: 10.1109/ICRA.2018.8460528 .[12] Z. Yuan, T. Wei, S. Cheng, G. Zhang, Y. Chen, 和 H. Xu. 学会在任何地方操作：强化学习的通用视觉框架，2024年10月.[13] H. Ha, Y. Gao, Z. Fu, J. Tan, 和 S. Song. UMI-on-Legs：通过以操作为中心的全身控制器使操作策略移动化。在第八届机器人学习年会上，2024年9月.[14] N. Rudin, D. Hoeller, P. Reist, 和 M. Hutter. 使用大规模并行深度强化学习在几分钟内学会行走。在第五届机器人学习会议论文集中，第91-100页。PMLR，2022年1月.[15] X. Cheng, K. Shi, A. Agarwal, 和 D. Pathak. 腿式机器人的极限跑酷。在2024年IEEE国际机器人与自动化会议（ICRA）上，第11443-11450页，2024年5月。doi: 10.1109/ICRA57147.2024.10610200 .[16] J. Tan, T. Zhang, E. Coumans, A. Iscen, Y. Bai, D. Hafner, S. Bohez, 和 V. Vanhoucke. 模拟到现实：为四足机器人学习灵巧运动。在机器人：科学与系统 XIV，第14卷，2018年6月。ISBN 978-0-9923747-4-7.

[17] F. Shi, Y. Kojio, T. Makabe, T. Anzai, K. Kojima, K. Okada, and M. Inaba. 无参考学习双足运动技能：辅助力课程. In A. Billard, T. Asfour, and O. Khatib, editors, Robotics Research, pages 304–320, Cham, 2023. Springer Nature Switzerland. ISBN 978-3-031-25555-7.[18] OpenAI, I. Akkaya, M. Andrychowicz, M. Chociej, M. Litwin, B. McGrew, A. Petron, A. Paino, M. Plappert, G. Powell, R. Ribas, J. Schneider, N. Tezak, J. Tworek, P. Welinder, L. Weng, Q. Yuan, W. Zaremba, and L. Zhang. 机器人手解决魔方, Oct. 2019.[19] T. Chen, M. Tippur, S. Wu, V. Kumar, E. Adelson, and P. Agrawal. 视觉灵巧性：手内新奇特物体形状的重排. Science Robotics, 8(84):eadc9244, Nov. 2023. doi: 10.1126/scirobotics.adc9244 .[20] Y. Chen, C. Wang, L. Fei-Fei, and K. Liu. 序列灵巧性：为长时程操作链式灵巧策略. In 7th Annual Conference on Robot Learning, Aug. 2023.[21] Y. Chen, C. Wang, Y. Yang, and K. Liu. 基于人运动数据的面向对象的灵巧操作. In 8th Annual Conference on Robot Learning, Sept. 2024.[22] T. Lin, K. Sachdev, L. Fan, J. Malik, and Y. Zhu. 人形机器人基于视觉的灵巧操作模拟到现实的强化学习, Feb. 2025.[23] Z. Fu, Q. Zhao, Q. Wu, G. Wetzstein, and C. Finn. HumanPlus：人形机器人模仿与跟踪. In 8th Annual Conference on Robot Learning, Sept. 2024.[24] X. Gu, Y.-J. Wang, X. Zhu, C. Shi, Y. Guo, Y. Liu, and J. Chen. 推进人形机器人运动：使用去噪世界模型学习掌握挑战性地形. In Robotics: Science and Systems XX. Robotics: Science and Systems Foundation, July 2024. ISBN 9798990284807. doi: 10.15607/RSS.2024.XX.058 .[25] T. Haarnoja, B. Moran, G. Lever, S. H. Huang, D. Tirumala, J. Humplik, M. Wulfmeier, S. Tun- yasuvunakool, N. Y. Siegel, R. Hafner, M. Bloesch, K. Hartikainen, A. Byravan, L. Hasen- clever, Y. Tassa, F. Sadeghi, N. Batchelor, F. Casarini, S. Saliceti, C. Game, N. Sreendra, K. Patel, M. Gwira, A. Huber, N. Hurley, F. Nori, R. Hadsell, and N. Heess. 使用深度强化学习为双足机器人学习敏捷足球技能. Science Robotics, 9(89): eadi8022, Apr. 2024. doi: 10.1126/scirobotics.adi8022 .[26] Y. Chebotar, A. Handa, V. Makoviychuk, M. Macklin, J. Issac, N. Ratliff, and D. Fox. 关闭模拟到现实的闭环：使用真实世界经验适应模拟随机化. In 2019 International Conference on Robotics and Automation (ICRA), pages 8973–8979, May 2019. doi: 10.1109/ICRA.2019.8793789 .[27] A. Z. Ren, H. Dai, B. Burchfiel, and A. Majumdar. AdaptSim：任务驱动模拟适应模拟到现实迁移. In Proceedings of The 7th Conference on Robot Learning, pages 3434–3452. PMLR, Dec. 2023.[28] P. Huang, X. Zhang, Z. Cao, S. Liu, M. Xu, W. Ding, J. Francis, B. Chen, and D. Zhao. 怎么出错了？通过可微因果发现关闭模拟到现实的差距. In Proceedings of The 7th Conference on Robot Learning, pages 734–760. PMLR, Dec. 2023.[29] G. Schoettler, A. Nair, J. A. Ojea, S. Levine, and E. Solowjow. 用于机器人工业插入任务的元强化学习. In 2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), pages 9728–9735, Oct. 2020. doi: 10.1109/IROS45743. 2020.9340848 .[30] A. Kumar, Z. Fu, D. Pathak, and J. Malik. RMA：腿部机器人快速运动适应, July 2021.

[31] H. Qi, A. Kumar, R. Calandra, Y. Ma, 和 J. Malik. 手内物体旋转通过快速运动适应. 在第 6 届机器人学习年度会议 , 2022 年 8 月 .[32] A. Kumar, Z. Li, J. Zeng, D. Pathak, K. Sreenath, 和 J. Malik. 为双足机器人适应快速运动适应. 在2022年IEEE/RSJ国际智能机器人与系统会议 (IROS), 页面 1161–1168, 2022年10月. doi: 10.1109/IROS47612.2022.9981091 .[33]Y. Sun, W. L. Ubellacker, W.-L. Ma, X. Zhang, C. Wang, N. V. Csomay-Shanklin, M. Tomizuka, K. Sreenath, 和 A. D. Ames. 双足运动中基于模型的控制器对未知动态的在线学习. IEEE机器人与自动化快报, 6 (4):8442–8449, 2021年10月. ISSN 2377-3766, 2377-3774. doi: 10.1109/LRA.2021.3108510 .[34] Y. Zhang, L. Ke, A. Deshpande, A. Gupta, 和 S. Srinivasa. 带有强化学习的樱桃采摘. 在机器人：科学与系统 XIX, 卷19, 2023年7月. ISBN 978-0- 9923747-9-2.[35] K. Lei, Z. He, C. Lu, K. Hu, Y. Gao, 和 H. Xu. Uni-O4：统一在线和离线深度强化学习与多步在线策略优化. 在第12届学习表示国际会议, 2023 年 10 月 .[36] H. Xiong, R. Mendonca, K. Shaw, 和 D. Pathak. 开放世界中针对关节对象的适应式移动操作. 2024年1月.[37] Y. Jiang, C. Wang, R. Zhang, J. Wu, 和 L. Fei-Fei. TRANSIC：通过在线校正学习从模拟到现实的策略迁移. 在第8届机器人学习年度会议, 2024年9月.[38] J. Luo, C. Xu, J. Wu, 和 S. Levine. 通过人在回路强化学习实现精确和灵巧的机器人操作, 2025年3月.[39] A. Gupta, R. Mendonca, Y. Liu, P. Abbeel, 和 S. Levine. 结构化探索策略的元强化学习 , 2018. URL https://arxiv.org/abs/1802.07245.[40]K. Rakelly, A. Zhou, D. Quillen, C. Finn, 和 S. Levine. 通过概率上下文变量进行高效离线策略元强化学习, 2019. URL https://arxiv.org/abs/1903.08254.[41] W. Yu, J. Tan, Y. Bai, E. Coumans, 和 S. Ha. 通过元策略优化学习快速适应, 2020. URL https://arxiv.org/abs/1909.12995.[42] X. B. Peng, E. Coumans, T. Zhang, T.-W. Lee, J. Tan, 和 S. Levine. 通过模仿动物学习敏捷的机器人运动技能, 2020. URL https://arxiv.org/abs/2004.00784.[43] W. Yu, V. C. Kumar, G. Turk, 和 C. K. Liu. 双足运动的模拟到现实迁移, 2019. URL https://arxiv.org/abs/1903.01390.[44] S. Huang, Z. Zhang, T. Liang, Y. Xu, Z. Kou, C. Lu, G. Xu, Z. Xue, 和 H. Xu. MEN- TOR：带有任务导向扰动的专家混合网络用于视觉强化学习, 2024年10月.[45] K. Xu, Z. Hu, R. Doshi, A. Rovinsky, V. Kumar, A. Gupta, 和 S. Levine. 从图像中进行灵巧操作：通过亚步引导实现自主现实世界RL. 在2023年IEEE国际机器人与自动化会议 (ICRA), 页面 5938–5945, 2023年5月. doi: 10.1109/ICRA48891.2023.10161493 .[46] R. Mendonca, E. Panov, B. Bucher, J. Wang, 和 D. Pathak. 通过自主现实世界RL持续改进移动操作. 在第8届机器人学习会议论文集, 页面 5204–5219. PMLR, 2025年1月.

[47] S. Ha, P. Xu, Z. Tan, S. Levine, 和 J. Tan. 在真实世界中用极少量人力学习行走。发表于《2020年机器人学习会议论文集》，第1110–1120页。PMLR, 2021年10月.[48] L. Smith, I. Kostrikov, 和 S. Levine. 公园漫步：用无模型强化学习在20分钟内学会行走，2022年8月.[49] P. Wu, A. Escontrela, D. Hafner, P. Abbeel, 和 K. Goldberg. DayDreamer：物理机器人学习的世界模型。发表于《第六届机器人学习会议论文集》，第2226–2240页。PMLR, 2023年3月.[50] L. Smith, Y. Cao, 和 S. Levine. 拓展你的极限：用真实世界强化学习实现机器人运动连续改进，2023年。URL https://arxiv.org/abs/2310.17634.[51] M. Bloesch, J. Humplik, V. Patraucean, R. Hafner, T. Haarnoja, A. Byravan, N. Y. Siegel, S. Tunyasuvunakool, F. Casarini, N. Batchelor, F. Romano, S. Saliceti, M. Riedmiller, S. M. A. Eslami, 和 N. Heess. 迈向真实环境中的机器人学习：双足运动案例研究。发表于 A. Faust, D. Hsu, 和 G. Neumann 编的《第五届机器人学习会议论文集》，机器学习研究论文集第164卷，第1502–1511页。PMLR, 2022年11月8–11日。URL https://proceedings.mlr.press/v164/bloesch22a.html.[52]ROBOTIS. ROBOTIS OP3 e-Manual. https://emanual.robotis.com/docs/en/ platform/op3/introduction/, 2024年。访问时间：2025-07-29.[53] J. Maples 和 J. Becker. 机器人机械臂力控制实验。发表于1986年IEEE国际机器人与自动化会议论文集，第3卷，第695–702页，1986年4月。doi: 10.1109/ROBOT.1986.1087590.[54] Y. Hou, Z. Liu, C. Chi, E. Cousineau, N. Kuppuswamy, S. Feng, B. Burchfiel, 和 S. Song. 自适应柔顺策略：学习扩散引导控制的大致柔顺性，2025年3月.[55] Y. Liang, T. Xu, K. Hu, G. Jiang, F. Huang, 和 H. Xu. Make-An-Agent：一种行为提示扩散的通用策略网络生成器。发表于《第三十八届神经信息处理系统大会》，2024年11月。

状态与动作表示

A.1 行走

遵循 Shi 等人 [9], 的强化学习训练设置， $\pi(\mathsf{s}_t)$ 和 $\pi(\boldsymbol{s}_t, z)$ 都输出 a_t 作为基于可观测状态 s_t 的比例 - 微分 (PD) 控制器的关节位置设定值:

$$\mathbf{s}_t = (\boldsymbol{\phi}_t, \mathbf{c}_t, \Delta\mathbf{q}_t, \dot{\mathbf{q}}_t, \mathbf{a}_{t-1}, \boldsymbol{\omega}_t, \boldsymbol{\theta}_t)\,, \tag{5}$$

其中 $\boldsymbol{\phi}_t$ 是一个阶段信号， $\boldsymbol{c}_t$ 表示速度指令， $\Delta\boldsymbol{q}_t$ 表示相对于中性姿态 $\boldsymbol{q}_0$ 的位置偏移， $\boldsymbol{a}_{t-1}$ 是前一时间步的动作， $\boldsymbol{\omega}_t$ 表示躯干的角速度，而 $\boldsymbol{\theta}_t$ 是躯干在欧拉角下的方向。

在模拟中，评价器的观察空间包含更多特权信息，以提供更好的值函数精度，我们有:

$$\mathbf{s}_t^{+} = \left(\boldsymbol{\phi}_t, \mathbf{c}_t, \Delta\mathbf{q}_t, \dot{\mathbf{q}}_t, \mathbf{a}_{t-1}, \mathbf{e}_{\mathbf{q}t}, \mathbf{v}_t, \boldsymbol{\omega}_t, \boldsymbol{\theta}_t, \mathbf{m}_t, \mathbf{ref}_t, \tilde{\mathbf{v}}_t, \tilde{\boldsymbol{\theta}}_t\right), \tag{6}$$

其中 $e\mathsf{q}_t$ 是当前电机位置到参考电机位置的误差，v_t 是机器人在世界坐标系中的线性 ˜ 速度，ref_t 是参考电机姿态，而 $\tilde{}\mathsf{v}_t$ 和 $\boldsymbol{\theta}_t$ 是施加到机器人上的随机扰动的线性和角速度。在现实世界中，由于模拟中的一些特权观察难以获取，我们利用 RTR 系统的力信息，并增强现实世界的特权观察为:

$$\mathbf{s}_t^{r+} = (\boldsymbol{\phi}_t, \mathbf{c}_t, \Delta\mathbf{q}_t, \dot{\mathbf{q}}_t, \mathbf{a}_{t-1}, \mathbf{q}_t, \mathbf{v}_t, \boldsymbol{\omega}_t, \boldsymbol{\theta}_t, \mathbf{F}_t, \boldsymbol{\tau}_t)\,, \tag{7}$$

其中 q_t 是人形机器人的关节位置，v_t 是由运动跟踪系统测量的躯干线性速度，而 F_t 和 $\boldsymbol{\tau}_t$ 是由安装在机器人手臂上的力矩传感器测量的力和力矩。

A.2 振荡起

对于振荡起任务，观测空间与公式5定义相同。我们还包含更多信息，形成任务的特殊观测空间:

$$\mathbf{s}_t^{+} = (\boldsymbol{\phi}_t, \mathbf{c}_t, \Delta\mathbf{q}_t, \dot{\mathbf{q}}_t, \mathbf{a}_{t-1}, \boldsymbol{\omega}_t, \boldsymbol{\theta}_t, \boldsymbol{F}_t, \boldsymbol{\tau}_t, \boldsymbol{x}_t) \tag{8}$$

其中 $\boldsymbol{F}_t$、 $\boldsymbol{\tau}_t$、 $\boldsymbol{x}_t$ 分别是力读数、扭矩读数和机械臂末端执行器位置。

B FiLM 消融

在本节中，我们讨论了模拟到真实适配流程中 FiLM 层的细节。如公式(1)所示，FiLM 层为隐藏网络的每一层引入缩放和偏移效果，从而改变策略网络的行为。

FiLM 层在训练过程中的一个关键考虑是其学习率，因为它决定了 FiLM 层相对于策略网络变化的速率。在我们的实现中，我们从零开始训练 FiLM 层和策略网络，因为我们发现从预训练模型初始化策略网络会削弱 FiLM 层对策略的影响。回想一下:

$$\gamma_j^{(i)}, \beta_j^{(i)} = \mathbf{FiLM}_j(z^{(i)}), \quad h_j^{(i)} \leftarrow \gamma_j^{(i)} \odot h_j^{(i)} + \beta_j^{(i)}$$

我们将所有 FiLM 层的权重初始化为零，偏置也初始化为零或全一，这样在训练开始时，我们有: $\gamma_j^{(i)} = 1.0, \beta_j^{(i)} = 0.0$，这意味着 FiLM 层不会影响网络输出。由于 FiLM 层与策略网络同时训练，它们处于竞争状态：策略网络在学习在当前 FiLM 分布下获得更好的整体性能，而 FiLM 层则被训练以利用环境的潜力和最大化在不同环境中的性能。

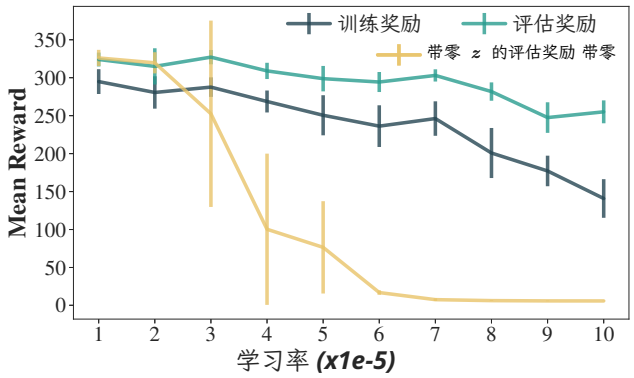


图6：FiLM学习率消融实验。本实验旨在评估FiLM层学习率的影响。所有实验均在七种种子下运行。垂直条表示标准差。

表2：我们对行走任务随机化了以下环境参数。

参数名称	摩擦力	阻尼	骨骼	摩擦损耗	体重	EE质量
随机化范围	$[0.5, 2.0]$	$[0.5, 2.0]$	$[0.5, 2.0]$	$[0.5, 2.0]$	$[-0.3, 0.3]$	$[0.0, 0.1]$

当前FiLM分布，而FiLM层则被训练以利用环境的潜力和最大化在不同环境中的性能。

我们发现，FiLM层的较小学习率会导致策略行为类似于未进行调制时的训练，从而限制了其在不同潜在条件下的泛化能力和对不同环境的适应能力。另一方面，如果学习率过大，则会引发训练不稳定并降低性能。

我们提出一种指标来衡量动态潜在条件化 $\pi(s, z)$利用嵌入在潜在 z中的环境信息的有效性。具体而言，我们比较了给定由动态编码器 $z^{(i)} = f_\phi(\mu^{(i)})$计算的真实潜在 z 和全零潜在时的策略性能，并发现当FiLM学习率较小时，全零潜力的性能甚至可以与给定真实z时的性能相媲美，但当学习率增加且策略开始学习使用潜在信息时，其性能会逐渐下降至接近零。另一方面，当FiLM学习率增加时，策略的整体性能会近似单调递减。我们在图6中绘制了不同学习率下的性能曲线。对于每个学习率，我们运行了七次试验，并绘制了性能的均值和标准差。我们发现，$5e-5$ 的学习率在性能和利用潜在信息的能力之间取得了良好的平衡，而 $1e-5$ 太小，导致零潜力和真实潜力性能几乎相同，而 $1e-4$ 太大，导致性能较差。

C 实验细节

C.1 域随机化

遵循 [9]，中的域随机化设置，我们将域随机化范围略微增加，以鼓励策略网络更好地利用来自潜空间的动态信息。我们将随机化参数及其范围列于表 2。我们使用来自 [55] 的编码器-解码器架构，将物理参数编码为 1024 维的潜空间，然后再将其发送到 FiLM 层，尽管在我们的实现中仅使用编码器。

C.2 机械臂控制策略

我们基于侯等人开源的代码实现了我们的应用臂控制器。[54] .

对于行走任务，我们启用沿XY轴的应用控制，同时直接设置Z高度。我们沿两个轴使用刚度为 $[100, 50]$，并将阻尼设置为 $[0.5, 0.5]$，惯性设置为 $[0.03, 0.03]$，使手臂在Y轴上略微更柔顺。

对于摆动任务，我们禁用手臂的设备控制，因为它会导致相位跟踪滞后。我们使用位置控制让手臂跟随第3.3节中描述的辅助或扰动运动。在辅助模式和扰动模式下，每个现实世界的数据收集周期都被均匀地分成5个区间。在辅助模式下，从最后4个区间中随机选择3个区间来应用辅助。在扰动模式下，从前4个区间中随机选择1个区间来应用扰动。

C.3 跑台控制策略

在行走任务中，机器人在跑台上行走，同时跑台动态调整速度以保持机器人处于良好位置。我们使用PD控制器来控制跑台速度 v:

$$v = v_{base} + k_p^1 F_x + k_p^2 \psi \tag{9}$$

其中 $v_{base} = 0.1$ m/s 是默认跑台速度， F_x is 是沿 x-轴的力读数， ψ是机器人的躯干俯仰角。 $k_p^1 = 0.2$ 和 $k_p^2 = -5$ 是比例增益。我们设置跑台速度限制为0.24 m/s，以确保人形平台的稳定性。

C.4 在线学习超参数

在真实世界的行走适应过程中，我们在使用 PPO 算法以 0.2 的裁剪率，在 1024 步数据上更新策略之前，会收集一批数据。动作网络和评价网络的优化都使用学习率 1×10^{-4}。为了鼓励探索，我们应用了 0.005 的熵系数。

为了从头开始训练摆起任务，我们在开始更新策略之前也会收集 1024 个样本。动作网络使用学习率 2×10^{-3} 进行优化，评价网络使用学习率 2×10^{-5} 进行优化。为了鼓励探索，我们应用了更大的熵系数 0.04。每个 PPO 更新都在 0.2 的裁剪率下进行 20 个 *epoch*。

C.5 真实世界学习细节

D 与 *RMA* 的比较

Rapad 运动适应 (RMA) [30] 是一种与我们的方法相似的模拟到现实适应方法。RMA 的训练分为两个阶段：(1) 预训练阶段，在模拟环境中使用领域随机化训练策略。在这个阶段，通过投影层将物理参数的潜在信息编码，然后与观察结果连接后发送到策略。 (2) 适应阶段，用于解决真实世界的物理参数未知的问题。在这个阶段，通过监督学习训练一个适应模块，以从过去的观察和动作中重建潜在 z 。

与RMA相比，我们的方法在每个阶段都存在差异：在第一阶段，我们的方法使用FiLM层来调制策略网络，这是一种更灵活、更强大的利用潜在信息的方式。相比之下，RMA只是将潜在信息与观察结果连接起来。在第二阶段，我们的方法不需要自适应模块来重建潜在 z，而是优化一个在所有环境中共享的通用潜在 z^* ，这可以作为进一步训练最优真实世界潜在 z^*_{real}的良好初始化。另一方面，RMA试图从过去的观察结果和动作中重建潜在 z ，这容易导致过拟合，尤其是在面对大量分布外真实世界动态时。

在以下部分，我们设置了模拟和现实世界的实验来比较我们的方法与RMA。我们试图回答以下问题：(1) FiLM层调制

对于每个实验，我们进行消融研究，并保持所有其他参数不变。然后，我们在真实世界中评估完全训练好的RMA模型，以证明我们的方法确实从每个角度都是真实世界适应的更好选择。

*D.1 RMA*实现细节

我们描述了在拟人化平台上实现RMA算法时使用的细节。在第一阶段训练中，我们使用附录C.1中描述的相同参数范围随机化模拟环境，然后将随机化的参数连接起来形成物理信息向量。在编码过程中，我们丢弃了不变的数字。

RMA算法最初是为具有相对较低自由度的四足机器人设计的。与原始实现相比，我们使用类似的过程来训练一个第一阶段模型，该模型接收观察和动力学潜空间，并输出动作。在第二阶段，我们对算法进行了以下更改以适应我们的硬件：(1)我们将过去用于预测当前动力学潜空间的观察和动作的窗口长度从50减少到15，因为拟人化平台的观察具有更高的维度，过长的范围会导致训练困难。此调整也与训练期间使用的栈帧长度一致。(2)我们相应地更改了用于处理过去状态和动作的一维卷积层，因为上下文窗口大小已减小。新的卷积层现在具有(5，3，3)的内核大小和(1，1，1)的步长。除了这些更改之外，RMA训练重用了现有的真实世界学习管道，而在第二阶段仅优化适应模块而不是动力学潜空间，这与RTR的实现不同。

D.2 FiLM 潜在调制

我们首先比较了 RTR 使用的 FiLM 层调制效果与 RMA 第一阶段使用的拼接方法。为此，我们运行了 RMA 的三个种子，在 1024 个并行模拟环境中训练一个动态潜在条件策略。虽然基于 FiLM 层的策略可以轻松达到平均评估回报超过 300，但拼接策略只能达到略高于 200 的回报。我们怀疑这是由于拼接引入的高维度导致的，这会阻碍策略性能。MLP 策略输入中同时存在观察值和动态潜在也可能导致网络忽略动态。详细结果可参见表 3 的第一列，其中“真实值”表示两种方法都可以直接访问编码器预测的动态潜在。

D.3 适应模块性能

在 RMA 的第二阶段，一个适应模块被训练用于根据过去的观察值预测动态潜在。而在 RTR 中，一个通用潜在会在随机环境中进行训练，用于真实世界学习阶段的初始化。我们想要研究哪种方法能够更好地估计真实动态潜在。除了在上一小节中研究的拼接或 FiLM 层调制的设计选择外，我们还进行了消融研究，以全面比较两种方法的性能。结果可参见表 3。

在表3的第一行中，我们使用RMA的第一阶段通过直接将动力学潜空间连接到观测值来训练一个动力学条件策略，这会导致其性能低于FiLM层。然后，我们使用通用潜空间优化和适应模块来预测动力学潜空间。结果表明，这两种方法都很好地恢复了潜空间，导致其性能与第一阶段使用的真实潜空间几乎相同。

在表3的第二行中，我们通过FiLM层将动态条件作用于策略，这与RTR中的方法相同。经过条件化的策略性能高于拼接的潜空间。然后，我们比较了两种方法在估计FiLM层动态潜空间方面的能力。这

表3：我们比较了RTR（我们）和RMA [30] 在本表格中每个阶段的性能 ble

	真实值	适配模块（RMA）	通用潜在（RTR）
连接（RMA）	210.32 ± 20.75	205.74 ± 15.63	207.32 ± 5.89
FiLM层（RTR）	316.10 ± 11.30	10.32 ± 2.01	$\boldsymbol{305.28 \pm 5.47}$

表4：本表比较RTR和RMA [30]，扩展了表1的结果。

方法	躯干滚转↓	躯干俯仰↓	外力X ↓	外力Y ↓	EE力Z ↓
RMA	0.167 ± 0.010	0.212 ± 0.006	1.172 ± 0.007	0.799 ± 0.028	2.548 ± 0.216
RTR（我们）	$\boldsymbol{0.093 \pm 0.020}$	$\boldsymbol{0.053 \pm 0.044}$	$\boldsymbol{0.943 \pm 0.202}$	$\boldsymbol{0.754 \pm 0.122}$	$\boldsymbol{0.954 \pm 0.445}$

段时间内，RMA风格的适应模块未能恢复FiLM层的可行动态潜空间，导致性能始终处于较低水平，几乎接近随机策略的水平。虽然适应模块的预测误差在减小，但我们怀疑这是由于FiLM层对动态层的小变化更为敏感，而适应模块无法完全弥补从过去观察和动作中产生的差距。

D.4 实际性能

最后，我们在实际环境中运行 RMA 模型，并使用与主论文相同的指标测试其性能。虽然我们的 RMA 方法实现成功适应实际环境，产生了与模拟类似行走行为，但 RMA 策略的行走步态不够稳定，人形机器人经常向前倾斜，并频繁由 RTR 硬件恢复。表 4 中的指标表明，我们的方法在实际环境适应方面明显优于 RMA。

总之，在训练的第一阶段，RTR 使用的 FiLM 层方法优于 RMA 使用的拼接方法。在第二阶段，我们的通用潜在优化方法可以提供与 RMA 类似的初始潜在值，并且与 FiLM 层结合时更稳定。此外，我们的通用潜在优化方法引入了第三阶段实际环境调优，并能够进一步借助 RTR 硬件提升实际性能。模拟和实际环境实验的结果表明，RTR 的动力学潜在优化流程比 RMA 使用的方法更适合人形机器人的模拟到实际环境适应。